

基于双层优化与差分进化算法的 NIPT 时点决策及异常判定模型

摘要

无创产前检测通过分析孕妇外周血中的胎儿游离 DNA，成为产前筛查的核心技术。该技术依赖于足够的胎儿 DNA 浓度以确保准确性，然而检测时点与孕妇个体差异均会影响该浓度，形成了早期检测与临床干预时机之间的矛盾。对于男胎，Y 染色体浓度是评估检测准确性的指标；但对于女胎，因缺乏此类特异性标志物，异常判定更具挑战性。因此，针对不同胎儿性别及孕妇特征，建立个体化的 NIPT 时点选择与异常判定模型，对降低出生缺陷风险至关重要。

对于问题一，为探究孕周、孕妇 BMI 等关键生理指标对胎儿 Y 染色体浓度的影响机制，本文构建了分层推进的回归模型。研究首先采用**分组一元线性回归**，独立剖析了孕周和 BMI 在不同生理条件下的单一影响模式；随后，为克服单一变量解释力不足的局限，进一步构建了整合孕周与 BMI 的**多元线性回归模型**，以评估其综合效应。研究表明：Y 染色体浓度与孕周呈显著正相关，与孕妇 BMI 呈显著负相关。

对于问题二，为最小化男胎孕妇因 NIPT 检测时点选择不当而导致的潜在风险，本文旨在对孕妇 BMI 进行合理分组，并为各群体推荐最优检测时点。为动态寻优 BMI 分组边界与各组的最佳检测时点，本文构建了一个创新的**双层优化模型**。该模型旨在最小化综合风险函数，该函数权衡了两种潜在风险：其一是因检测时点过晚而导致治疗窗口期缩短的风险；其二是因 Y 染色体浓度未达 4% 阈值而引致检测结果不准确的风险。鉴于该目标函数的非光滑与黑盒特性，我们采用**差分进化算法**对这一高维、非凸问题进行全局寻优，最终求解出最优的 BMI 分组方案及相应的最佳 NIPT 时点。

对于问题三，在问题二的基础上，构建一个综合考虑多维生理因素、检测误差及群体达标比例、更为稳健的 NIPT 时点推荐策略。为此，模型在预测精度，通过 VIF 检验与 XGBoost 加 SHAP 分析，筛选并融入了体重、年龄等多维核心变量；同时，引入概率约束将检测误差内化于模型，采用分位数满足群体达标率的要求。在求解上，重构“适应度评估”函数，封装复杂的多因素回归。这一优化问题最终由差分进化算法进行全局寻优，从而求解出最优的 BMI 分组方案及相应的最佳 NIPT 时点。

对于问题四，为解决女胎 NIPT 因缺乏特异性标志物而导致的异常判定难题，本文构建了一个融合多维特的 **SVM 模型**。该模型旨在应对数据分布不均的情况，为此，我们采用过采样技术处理训练集，并以 F1 分数为核心指标进行调优与评估。最终，训练得到的 SVM 模型表现良好：具有极高特异性与敏感性。

最后，本文通过递进式的建模路径，为 NIPT 检测提供了兼具个体化与鲁棒性的时点优化及异常判定策略，为提升精准产前筛查水平提供了理论支持与实践方案。

关键字： 多元线性回归 双层优化模型 差分进化算法 SVM 模型 NIPT 时点决策

一、问题重述

1.1 问题背景

近年来，胎儿染色体非整倍体疾病已成为新生儿出生缺陷的主要致病因素，其临床发病率高，表现为严重智力障碍、多系统畸形及心脏结构异常，并伴随显著的围产儿死亡率，对患儿生活质量、家庭幸福及社会医疗资源造成深远影响^[1]。随着我国生育政策调整及优生优育理念普及，产前检查已成为出生缺陷防控与胎儿健康保障的核心环节。羊膜穿刺、绒毛取样及脐带血穿刺等传统产前诊断技术可直接获取胎儿遗传信息并实现精确核型分析，但均为侵入性操作，存在流产、感染等风险，且多需在孕中晚期实施，导致异常发现延迟，孕妇的生育选择与临床干预窗口受到限制。因此，开发早期、无创且高效的产前检测技术成为临床迫切需求^[2]。

无创产前检测（NIPT）是一项核心产前筛查技术，它通过分析孕妇外周血中的胎儿游离 DNA（cffDNA），可在孕早期安全、便捷地评估 21、18、13 三体综合征等风险。然而，该技术的准确性高度依赖于 cffDNA 的浓度，即胎儿分数（FF），这构成了检测时点选择的核心矛盾：检测过早，FF 浓度可能不足，影响准确性；检测过晚，虽准确性提高，却缩短了宝贵的临床干预窗口。同时，孕妇的高 BMI 等个体因素会进一步稀释 FF，加剧了结果的不确定性。因此，如何根据个体差异优化检测时点，平衡早期筛查与检测成功率，是提升 NIPT 临床应用价值的关键，也是本文研究的重点。

对于男性胎儿，母体外周血中的 Y 染色体片段具有高度特异性，能够明确区分于母体 cfDNA 背景。这一特异性使 Y 染色体片段可作为常染色体异常检测的定量内参，既保证了 NIPT 在孕早期的高灵敏度与高特异性，又降低了母体 DNA 背景噪声对检测结果干扰，为常染色体非整倍体疾病的早期风险评估提供了稳健的分子依据。然而，女性胎儿缺 Y 染色体特异性片段，无法直接估算 FF。现有方法仅能依赖 cffDNA 片段长度分布、单核苷酸多态性（SNP）或差异甲基化模式等间接手段，这些方法易受母体 cfDNA 背景噪声干扰，检测灵敏度和特异性相对不足，成为 NIPT 在女性胎儿应用中的关键技术难点^[3]。基于上述背景，本研究拟通过分析孕妇个体特征及胎儿性别差异，优化 NIPT 检测时点与 FF 估算方法，实现男女胎儿均可高精度检测，同时兼顾充分的临床干预窗口，为产前筛查的个体化应用提供理论依据与实践指导^[4]。

因此，本研究旨在构建一套个体化 NIPT 优化策略。具体而言，我们将建立预测模型以确定不同孕妇群体的最佳检测时点，并针对女性胎儿的检测难点探索更精准的 FF 估算方法。我们期望通过此策略与技术的双重优化，提升整体产前筛查水平，为降低出生缺陷率提供实践方案^[5]。

1.2 问题要求

问题 1 要求对胎儿 Y 染色体浓度、孕妇孕周及 BMI 这三个核心变量之间的相关性进行分析并且验证显著性。

问题 2 要求基于孕妇的 BMI，为怀有男胎的孕妇设计一个最佳 NIPT 时机推荐策略。给出 BMI 的合理分组，并为每个组别确定一个能最小化综合风险的检测时间点，该风险是权衡了因检测过早导致 Y 染色体浓度不足而测试失败的风险，与因检测过晚而延误临床诊断风险后的结果。此外，还需要分析检测中存在的误差影响。

问题 3 要求综合孕妇的 BMI、年龄、检测误差和胎儿的 Y 染色体浓度达标比例等多种因素建立概率模型，以确定能在“高检测成功率”与“避免诊断延迟”之间取得最佳平衡的 NIPT 检测时点，并分析误差影响。

问题 4 要求综合分析女胎孕妇的 Z 值、测序数据及 BMI 等多维信息，构建一个能够准确判定女胎是否存在 21、18、13 号染色体非整倍体异常的算法。

二、问题分析

2.1 问题一分析

问题一要求量化 Y 染色体浓度与孕周、BMI 等因素的复杂关系，我们采用分层递进的建模策略。首先，通过一系列分组一元回归，独立剖析各核心变量在不同生理条件下的主效应；随后，构建多元线性回归模型，将关键变量整合以评估其综合影响，从而建立一个更全面的预测模型。

2.2 问题二分析

为确定最优的 BMI 分组及各组 NIPT 时点，我们将此问题构建为一个统一的优化模型。该模型通过一个综合风险函数，权衡“检测过早”（浓度不足）与“检测过晚”（延误诊断）的风险，并以 BMI 分组边界和各组推荐孕周为联合决策变量进行求解。由于目标函数因动态分组而呈非光滑、非凸特性，我们采用差分进化算法进行全局寻优，以获得最优的分组与时点策略。

2.3 问题三分析

问题三要求综合考量多因素影响，我们首先利用 VIF 模型去除共线性的影响，运用 XGBoost 与 SHAP 筛选核心变量。在此基础上，我们引入概率约束来处理检测误差，并采用分位数决策来保证群体达标率，从而将风险控制内化为模型的硬性约束。最终，模型以最小化平均检测孕周为目标，通过差分进化算法求解最优的 BMI 分组边界，从而得出一套更精细、更稳健的个性化 NIPT 时点策略。

2.4 问题四分析

问题四要求解决女性胎儿 NIPT 因缺乏特异性标志物而面临的诊断难题。传统的单 Z 值阈值法在这种场景下灵敏度与特异性受限，难以应对复杂的情况。为此，本研究的核心是从单一指标判定转向多维特征的综合诊断范式，通过构建一个非线性支持向量机分类模型，旨在利用其强大的核技巧来捕捉各染色体 Z 值、孕妇 BMI 及测序指标间复杂的、非线性的潜在关联。该方法在实施中必须应对临床数据固有的严重类别不平衡问题，最终目标是生成一个稳健、可靠的异常判定方法，为临床提供决策支持。

综合上述分析，本研究的总体技术路线如图1所示：




图 1 研究流程图

基于本文所使用的数据，将其进行可视化分析，以展示其总体分布特征如图 2：




图 2 数据分布特征

三、模型假设

为确保本研究中所构建模型的有效性与合理性，我们提出以下基本假设：

- **假设 1：数据的代表性与一致性**

假设所使用的数据集（男胎与女胎）是相应孕妇群体的无偏代表性抽样，能够反映真实世界中各生理指标的分布与关联。

- **假设 2：核心关系的线性近似**

在问题一至三的回归与优化模型中，我们假设因变量（Y 染色体浓度）与核心自变量（如孕周、BMI、体重等）之间的关系是线性的，或可以通过线性关系进行有效近似。这是我们采用一元及多元线性回归作为预测引擎的基础。

- **假设 3：误差项的统计特性**

对于所有回归模型，我们假设其随机误差项 ϵ 相互独立，且服从均值为 0 的正态分布，并具有恒定的方差（即同方差性）。这一经典线性回归假设是模型参数显著性检验（t 检验、F 检验）和问题三中概率约束推导的必要前提。

- **假设 4：单胎妊娠**

假设所有纳入分析的孕妇均为单胎妊娠，不考虑双胞胎或多胞胎等可能影响胎儿游离 DNA 浓度的复杂情况。

- **假设 5：风险的可量化与可加性**

在问题二的优化模型中，我们假设“检测过晚的临床风险”与“浓度不达标的检测风险”是可以被量化，并通过一个带权重的目标函数进行综合考量的。即假设不同性质的风险可以被统一在一个框架下进行权衡与优化。

四、符号说明

表 1 符号说明表

符号	说明	单位/类别
Y	因变量，特指 Y 染色体浓度	%
$\hat{Y}$	Y 染色体浓度的模型预测值	%
X	一元线性回归模型中的通用自变量	-
X_{week}	自变量，孕周	周
X_{bmi}	自变量，孕妇身体质量指数 (BMI)	kg/m ²
$\beta_0, \beta_i, \beta_j$	线性回归模型中的系数 (β_0 为截距项)	-
$\mathbf{B}_j$	第 j 个分层回归模型的系数向量	-
ϵ	回归模型的随机误差项	%
R^2, R_{adj}^2	决定系数与调整后决定系数	无
$\mathbf{A}, \mathbf{A}^*$	BMI 分组边界调整参数向量及其最优解	kg/m ²
$\alpha_1, \alpha_2, \alpha_3$	BMI 分组边界的具体调整值	kg/m ²
b_j	BMI 分组的临界点/边界值	kg/m ²
T_j, t_j	第 j 组的推荐 NIPT 时点	周
$X_{\text{week}, i}^*$	样本 i 的理论最优 (最早可达标) NIPT 时点	周
C_{thresh}	Y 染色体浓度临床标准阈值 (本文设为 0.04)	%
λ	目标函数中损失项的权重/惩罚系数	无
VIF_i	第 i 个自变量的方差膨胀因子	无
$\hat{y}_i$	XGBoost 模型对样本 i 的预测值	%
σ_j	第 j 组回归模型的残差标准差，量化检测误差	%
p	个体浓度达标的置信水平 (概率约束)	无
q	组内群体达标的比例 (分位数约束)	无
z_{1-p}	标准正态分布的 $1 - p$ 分位数	无
C	SVM 中的惩罚系数/正则化参数	无
γ	RBF 核函数的参数，控制影响范围	无
$\mathbf{w}, b$	SVM 决策超平面的权重向量和偏置项	-
ξ_i	软间隔 SVM 中的松弛变量	无
α_i	SVM 对偶问题中的拉格朗日乘子	无
$\mathcal{H}$	模型超参数的搜索空间	-

五、问题一的模型的建立与求解

已有相关临床研究表明，胎儿游离 DNA 中 Y 染色体的浓度受到孕周数、孕妇 BMI、年龄及生产次数等多种影响因素交互影响^[1]。为厘清孕周、BMI 等多个交互因素对 Y 染色体浓度的复杂影响，本研究采用分层推进的建模思路。我们首先通过一系列分组一元回归，独立剖析各核心变量的主效应；随后在此基础上建立多元线性回归模型，评估这些因素的综合作用模式，从而系统性地揭示其影响规律。

5.1 一元线性回归模型

5.1.1 模型建立

为剥离混杂因素的干扰，独立地考察单一变量对 Y 染色体浓度的影响，本文采用分组控制变量的方法。该方法的核心是分别逐个探究核心自变量（孕周、BMI）与因变量（Y 染色体浓度）的关系时，依据其他协变量（年龄、生产次数等）的特征对样本数据进行分组。在每个组别内部，我们建立一元线性回归模型：

$$Y = \beta_0 + \beta_1 X + \epsilon$$

其中， Y 代表 Y 染色体浓度， X 为核心自变量（孕周、BMI）， β_1 为模型拟合的斜率， ϵ 为随机误差项。

本文旨在分别探究 Y 染色体浓度与孕周、BMI 两大核心关系，因此采用了两套分析流程：

- (1) 以“孕周”为自变量 X ，使用（年龄、孕妇 BMI、生产次数）作为分层变量。
- (2) 以“孕妇 BMI”为自变量 X ，使用（年龄、孕周、生产次数）作为分层变量。

5.1.2 分组依据

在两个分析流程中，均引入分层控制策略，以尽可能降低混杂因素对模型估计的干扰。具体而言，样本按照孕妇年龄（以 35 岁为界）^[6]、BMI（每 2 为间隔划分区间）、生产次数（0 次与 ≥ 1 次）以及孕周（早期、中期、晚期）进行分组。

5.1.3 模型评价指标

我们对前述建立的两个分析流程分别进行求解。核心评估指标包括：调整后决定系数 (R_{adj}^2)，它衡量了自变量对因变量变化的解释程度；以及核心自变量系数的 p 值，它判断了线性关系是否显著（通常以 $p < 0.05$ 为显著标准）。

5.1.4 结果与分析

关系一：Y 染色体浓度与孕周的关系

本节旨在探究 Y 染色体浓度与孕周是否呈线性关系，以及该种关系是否受到其他因素的调节。本研究结果显示，如图 3，不同组别 Y 染色体浓度与孕周均存在正相关关系，但其显著性与强度在不同组别中存在明显差异。

其中，各年龄段中小于 35 岁的组别 R^2_{adj} 显著大于 35 岁以上的组，表明 35 岁以下的组别中 Y 染色体浓度与孕周数呈现更加显著的正相关关系。各 BMI 组别中 Y 染色体浓度与孕周数均呈现显著正相关关系，且其相关关系及斜率均随 BMI 的增长而呈现总体增长趋势，在 BMI 达到 40 以上时， R^2_{adj} 达到 0.441。各生产次数组别中，经产妇 Y 染色体浓度与孕周数之间的相关关系显著大于初产妇。

表 2 Y 染色体浓度 vs 孕周的分组回归结果汇总

分层变量	分组	样本数	调整后 R^2	孕周系数 (β_1)	Slope	p 值*
年龄	年龄 < 35 岁	1014	0.016	0.0011	0.001078	< 0.001
	年龄 $\geq$ 35 岁	65	0.000	0.0009	0.000935	0.316
BMI	BMI: 28–30	205	0.029	0.0018	0.001788	0.009
	BMI: 30–32	332	0.031	0.0015	0.001482	0.001
	BMI: 34–36	153	0.037	0.0015	0.001532	0.010
	BMI: 36–38	67	0.101	0.0025	0.002452	0.005
	BMI: 40–42	9	0.441	0.0054	0.005419	0.030
生产次数	0 次 (初产妇)	748	0.005	0.0006	0.000649	0.030
	$\geq$ 1 次 (经产妇)	331	0.046	0.0019	0.001852	< 0.001

* 注：为简洁起见，BMI 分层仅展示关系显著的组别。p 值小于 0.05 的用粗体标出。




图 3 不同组别 Y 染色体浓度与孕周数关系 (a) R^2_{adj} 及 p 值 (b) 斜率

关系二：Y 染色体浓度与孕妇 BMI 的关系

本节旨在探究不同组别孕妇 BMI 对 Y 染色体浓度的影响。如图 4 所示，整体上 Y 染色体浓度与孕妇 BMI 存在负相关关系，各组别间显著性及相关性均有显著差异。但效应强度因人群而异。该效应在 35 岁以下及孕中期的孕妇中表现更稳定，且在初产妇中极其显著，但在经产妇中则无统计学意义。

表 3 Y 染色体浓度 vs 孕妇 BMI 的分组回归结果汇总

分层变量	分组	样本数	调整后 R^2	BMI 系数 (β_1)	Slope	p 值
年龄	年龄 < 35 岁	1014	0.023	-0.0017	-0.00174	< 0.001
	年龄 $\geq$ 35 岁	65	-0.006	-0.0013	-0.00126	0.437
孕周	< 12 周 (早期)	56	0.042	-0.0027	-0.0027	0.071
	12-27 周 (中期)	1020	0.023	-0.0017	-0.0017	< 0.001
生产次数	0 次 (初产妇)	748	0.041	-0.0023	-0.0023	< 0.001
	$\geq$ 1 次 (经产妇)	331	0.000	-0.0006	-0.0006	0.289




图 4 不同组别 Y 染色体浓度与孕妇 BMI 关系 (a) R^2_{adj} 及 p 值 (b) 斜率

5.2 回归模型分析对比

分组一元线性回归分析为我们揭示了各因素在不同条件下的影响模式，但也暴露了其内在局限性：尽管分组一元回归揭示了初步趋势，但其局限性也十分明显：模型的解释力不足， R^2 值均处于较低水平（普遍低于 6%）、无法完全排除变量间的潜在混杂效应，且集成度低、难以复用于后续的多因素预测。为克服这些不足并系统性地评估综合效应，我们转而构建了一个核心的多元线性回归模型。该模型整合了孕周和 BMI 两个关键自变量，并为保证简洁性与实用性，暂未纳入年龄等其他次要因素。

5.3 多元线性回归模型

5.3.1 模型建立

本研究整合孕周、BMI 两个核心自变量，建立如下二元线性回归模型：

$$Y = \beta_0 + \beta_1 X_{week} + \beta_2 X_{bmi} + \epsilon$$

其中， Y 为 Y 染色体浓度， X_{week} 为孕周、 X_{bmi} 为孕妇的 BMI 数值。 β_1 和 β_2 分别表示孕周和 BMI 对 Y 染色体浓度的回归系数，衡量了孕周和 BMI 数值对 Y 的独立影响。 β_0 为模型的截距项，代表所有自变量为 0 时 Y 染色体浓度的基准值。 ϵ 随机误差项，代表了模型未能解释的其他因素的影响。

5.3.2 结果分析

本研究采用普通最小二乘法（Ordinary Least Squares, OLS）对模型参数进行估计，以最小化预测值与实际观测值之间的残差平方和。对 1079 例清洗后的有效样本进行拟合，结果如表4所示。

表 4 多元线性回归模型结果汇总

变量	系数 (β_i)	标准误 (std err)	t 统计量	p 值 ($P> t $)
Intercept	0.3531	0.021	17.179	< 0.001
孕周 (week)	0.0023	0.000	4.851	< 0.001
BMI (bmi)	-0.0036	0.000	-5.964	< 0.001

模型整体评估：调整后 $R^2 = 0.048$ ；F 检验 p 值 = 1.72×10^{-11} 。

对模型拟合结果的分析表明，该多元线性回归模型在整体上是统计显著的（ F 检验 p 值 = $1.72 \times 10^{-11} \ll 0.05$ ），证明了孕周和 BMI 两个变量能联合有效地解释 Y 染色体浓度的变化。从拟合优度来看，模型的 R^2_{adj} 为 0.048，这说明模型能解释约 4.8% 的变异；虽然该值不高，反映了 Y 染色体浓度受到众多复杂因素影响，但模型仍成功捕捉到了关键的线性趋势。在各变量的独立效应方面，孕周的回归系数为正（0.0023, $p < 0.001$ ），与 Y 染色体浓度呈显著**正相关关系**；而孕妇 BMI 的系数为负（-0.0036, $p < 0.001$ ），呈显著**负相关关系**。这些影响方向与一元回归的探索结果一致，验证了模型的稳健性。最终，我们得到的关系模型表达式为：

$$\hat{Y} = 0.0023X_{week} - 0.0036X_{bmi} + 0.3531$$

模型可视化 为直观展示各关键变量的独立效应，我们绘制了部分回归图（见图5）。图中拟合线的斜率，即为表4中对应变量的系数值。从图中直线走向更能观察到 Y 染色体浓度随孕周和 BMI 的变化趋势。




图5 (a) 孕周与 (b) 孕妇 BMI 对 Y 染色体浓度的部分回归图

5.4 模型结论

通过本次建模分析，我们最终确定 Y 染色体浓度主要受到孕周和孕妇 BMI 的显著影响。具体而言，Y 染色体浓度随孕周增加而增加，随 BMI 的增加而降低。该模型的建立为后续进行 BMI 区间的分组和最佳 INPT 时点的确定提供了坚实的理论依据。在后续章节中，我们将利用此模型来构建风险函数，以寻求风险最小化的最佳 NIPT 检测策略。

六、问题二的模型建立和求解

6.1 模型分析

6.1.1 模型目标与核心问题

本部分旨在为处在不同 BMI 区间的孕妇群体推荐最优的无创产前检测（NIPT）时点，以实现疾病的早期筛查，从而减少因治疗窗口期缩短所带来的潜在风险。基于问题一建立的多元回归模型，我们可以预测特定孕妇在不同孕周的胎儿 Y 染色体浓度，这为决策提供了理论基础。因此，本问题的核心在于如何对男胎孕妇的 BMI 进行合理分层，并为各分层群体确定一个既安全又高效的最佳 NIPT 时点窗口。

6.1.2 关键约束条件

模型构建必须遵循一项关键的临床准则：为保证检测的准确性与可靠性，NIPT 要求胎儿游离 DNA 的浓度不低于某一阈值。根据临床实践标准，本模型设定 Y 染色体浓度的安全阈值为 4%，推荐的 NIPT 时点要使绝大多数预测的浓度满足此条件的前提下，尽可能小。

6.1.3 双层优化模型框架

我们将求解 BMI 区间内最佳 NIPT 时点转化为最小化损失函数，从而使得孕妇可能的潜在风险最小，最后通过分析目标函数结果随数据波动的变化完成检测误差对结果的影响。为解决上述问题，我们设计并构建了一个双层优化模型。该模型的总体目标是在满足检测成功率的前提下，最小化全体孕妇的 NIPT 时点之和与损失函数，给出男胎孕妇的 BMI 分组区间和最佳 NIPT 时点。模型由外层和内层优化构成：

外层优化：外层模型的目标是寻找最优的 BMI 分组边界点 $\mathbf{A}^* = (\alpha_1^*, \alpha_2^*, \alpha_3^*)$ 和每组 BMI 最佳 NIPT 时点 T_j ，通过调整未知参数，在全局上最小化所有孕妇群体的理论 NIPT 时点和损失函数。

内层优化：在外层给定了具体的 BMI 分组方案 $\mathbf{A}$ 后，内层模型针对每个组内的孕妇个体，求解其满足 Y 染色体浓度不低于 4% 这一条件的、理论上最早的 NIPT 时点。

综上所述，该双层优化结构将全局性的分组策略寻优（求解最优参数 $\mathbf{A}^*$ ）与 BMI 分组区间内的最佳时点推荐（求解最佳 NIPT 时点的 T_j ）有机地结合在一起，最终形成一个目标明确、约束清晰的数学规划问题，可通过相应的优化算法进行求解。

6.2 模型建立

为实现对孕妇的精准分组与个性化 NIPT 时点推荐，我们构建了一个以最小化全体孕妇平均送检风险为目标的统一优化模型。模型的决策核心是寻找最优的分组边界调整参数 $\mathbf{A}^* = (\alpha_1^*, \alpha_2^*, \alpha_3^*)$ 和最佳 NIPT 时点的 T_j 。

该模型的目标函数综合考虑了检测的“早期性”与“有效性”。一方面，我们追求更早的检测时间以降低风险；另一方面，必须严格保证在推荐的检测时点，组内绝大多数成员的 Y 染色体浓度预测值均不低于 4% 的临床阈值。为此，我们引入了基于组别推荐时点 T_j 的加权平均孕周作为总优化目标，并通过引入损失函数惩罚项来确保检测的有效性。

最优的分组参数 $\mathbf{A}^*$ 和每个 BMI 分组对应的最佳 NIPT 时点 T_j^* 正是能够使这个总目标函数最小化的解。该优化问题的数学范式如下：

$$\begin{aligned}
& \min_{\mathbf{A}, \{T_j\}} \quad \frac{1}{N} \sum_{i=1}^N X_{\text{week},i}^* + \lambda \sum_{j=1}^4 I_j(X_{\text{bmi},i}; \mathbf{A}) \cdot \ell_j(\hat{Y}) \\
& \text{s.t.} \quad \begin{cases} \mathbf{B}_j = \arg \min_{\beta_j} \sum_{i \in G_j(\mathbf{A})} (Y_i - (\beta_{0,j} + \beta_{1,j} X_{i,\text{week}} + \beta_{2,j} X_{i,\text{bmi}}))^2, \quad \forall j \in \{1..4\} \\ X_{\text{week},i}^* = \sum_{j=1}^4 I_j(X_{\text{bmi},i}; \mathbf{A}) \cdot f_{\text{week}}(X_{\text{bmi}}; \mathbf{B}_j) \\ \ell_j(\hat{Y}) = \max(0, C_{\text{thresh}} - \hat{Y}) \\ \mathbf{A} \in \mathbb{R}_+^3 \end{cases}
\end{aligned} \tag{1}$$

where:

- $G_j(\mathbf{A})$ 是分组集合，由参数向量 $\mathbf{A}$ 定义：

$$\begin{cases} G_1(\mathbf{A}) = \{i \mid X_{i,\text{bmi}} < 18.5 + \alpha_1\} \\ G_2(\mathbf{A}) = \{i \mid 18.5 + \alpha_1 \leq X_{i,\text{bmi}} < 24.0 + \alpha_2\} \\ G_3(\mathbf{A}) = \{i \mid 24.0 + \alpha_2 \leq X_{i,\text{bmi}} < 28.0 + \alpha_3\} \\ G_4(\mathbf{A}) = \{i \mid X_{i,\text{bmi}} \geq 28.0 + \alpha_3\} \end{cases} \tag{2}$$

- $I_j(X_{\text{bmi},i}; \mathbf{A})$ 是示性函数：

$$I_j(X_{\text{bmi},i}; \mathbf{A}) = \begin{cases} 1, & \text{if } i \in G_j(\mathbf{A}) \\ 0, & \text{if } i \notin G_j(\mathbf{A}) \end{cases} \tag{3}$$

- $f_{\text{week}}(X_{\text{bmi}}; \mathbf{B}_j)$ 是个体最优孕周的解析解：

$$f_{\text{week}}(X_{\text{bmi}}; \mathbf{B}_j) = \frac{0.04 - \beta_{0,j} - \beta_{2,j} X_{\text{bmi}}}{\beta_{1,j}} \tag{4}$$

- $\ell_j(\hat{Y}_i)$ 是基于 Hinge Loss 定义的、针对个体 i 的风险度量函数：

$$\ell_j(\hat{Y}_i) = \max(0, C_{\text{thresh}} - \hat{Y}_i) \tag{5}$$

上述计算中涉及的核心函数和参数定义如下

最优分组参数 $\mathbf{A}^*$ ：代表最优的 BMI 分组边界调整值。它是一个由三个正实数组成的向量 $\mathbf{A}^* = (\alpha_1^*, \alpha_2^*, \alpha_3^*)$ 。这三个值是用于动态调整标准 BMI 分组边界 (18.5, 24.0, 28.0) 的修正量，以形成最优化的四个孕妇组别，使得整个数据集中所有孕妇的预测 NIPT 时点 $\frac{1}{N} \sum X_{\text{week},i}^*$ 达到全局最小值。

系数向量 $\mathbf{B}_j(\mathbf{A})$ ：这是第 j 组的预测模型参数。对于由特定参数 $\mathbf{A}$ 划分出的每一个孕妇分组 $G_j(\mathbf{A})$ ，通过普通最小二乘法 (OLS) 拟合一个独立的多元线性回归模型： $Y \approx \beta_{0,j} + \beta_{1,j}X_{\text{week}} + \beta_{2,j}X_{\text{bmi}}$ 。公式所求解的，正是这个模型中的系数向量 $\mathbf{B}_j = (\beta_{0,j}, \beta_{1,j}, \beta_{2,j})$ 。

基于 Hinge Loss 定义的、针对个体 i 的风险度量函数 $\ell_j(\hat{Y}_i)$ ： $C_{\text{thresh}} = 0.04$ 为临床浓度阈值。此函数用于量化在组别推荐时点 T_j 进行检测时，个体 i 未能达标的风险程度。当预测浓度 $\hat{Y}_i$ 不低于阈值时，风险为 0；否则，风险为差值 $C_{\text{thresh}} - \hat{Y}_i$ 。其中，预测浓度 $\hat{Y}_i$ 的计算方式为：

$$\hat{Y}_i = \beta_{0,j} + \beta_{1,j}T_j + \beta_{2,j}X_{i,\text{bmi}} \quad (6)$$

这里， T_j 是第 j 组的统一推荐 NIPT 时点， $(\beta_{0,j}, \beta_{1,j}, \beta_{2,j})$ 是由分组方案 $\mathbf{A}$ 确定的第 j 组数据的 OLS 回归系数。

最优 NIPT 时点求解函数 $f_{\text{week}}(\cdot)$ ：该函数用于计算满足临床阈值前提下，理论上可能的最早 NIPT 时点 X_{week} 。其函数表达式通过求解一个带约束的最小化问题得出，详细推导过程如下：

1. 首先，建立优化问题：目标是最小化 NIPT 时点 X_{week} ，约束条件是预测的 Y 染色体浓度不低于 0.04。

$$\begin{aligned} \min \quad & X_{\text{week}} \\ \text{s.t.} \quad & \beta_{0,j} + \beta_{1,j}X_{\text{week}} + \beta_{2,j}X_{\text{bmi}} \geq 0.04 \end{aligned}$$

2. 接着，对不等式约束进行代数变换，求解 X_{week} 的可行域：

$$\beta_{1,j}X_{\text{week}} \geq 0.04 - \beta_{0,j} - \beta_{2,j}X_{\text{bmi}}$$

3. 基于孕周与 Y 染色体浓度正相关的临床事实，我们有 $\beta_{1,j} > 0$ 。因此，在不等式两边同除以 $\beta_{1,j}$ ，不等号方向不变：

$$X_{\text{week}} \geq \frac{0.04 - \beta_{0,j} - \beta_{2,j}X_{\text{bmi}}}{\beta_{1,j}}$$

4. 最后，根据最小化目标，最优解 X_{week}^* 应取其可行域的下界。这就得到了公式 (4) 所定义的解析解。

6.3 模型求解

6.3.1 求解难点与差分进化算法的适用性分析

该优化问题在结构上是一个复杂的双层优化问题，其固有的难点使得传统优化方法难以奏效，同时也凸显了采用差分进化算法 (DE) 的必要性与优越性。具体分析如表：

表 5 模型求解难点与差分进化算法适用性分析

模型求解难点	差分进化算法 (DE) 的对应优势
目标函数的“黑盒”特性 目标函数将数据分组、成本计算和风险惩罚等多个步骤封装在一起。其内部逻辑复杂，无法写出决策变量的显式解析表达式，呈现“黑盒”特性。	黑盒优化适应性 差分进化算法作为一种基于种群的启发式算法，其优化过程不依赖于目标函数的具体代数结构或梯度信息。算法仅需根据输入的参数向量获得一个总风险评价值，即可引导搜索，能够高效处理此类复杂函数。
目标函数的非光滑与不可导性 由于决策变量 b_j 用于数据分组，导致目标函数值呈阶跃式变化，因而是非光滑的。同时，我们采用的合页损失函数在部分点不可导。这些特性使得传统的梯度下降等算法完全失效。	梯度无关的搜索机制 差分进化算法通过变异、重组和选择等算子驱动种群进化，这些算子完全不涉及梯度计算。算法通过直接比较父代与子代解的优劣进行迭代，因此目标函数的非光滑、不可导等性质不会对算法的执行构成任何障碍。
解空间的高维非凸性与“平坦”区域 七个决策变量间存在复杂的耦合关系，构成了高维、非凸的搜索空间，其中存在大量局部最优解。更关键的是，对于分组临界点 b_j，其微小变动往往不改变函数值，形成了大片“平坦”区域，导致梯度类算法无法移动。	强大的全局探索能力 差分进化算法通过维护一个解种群进行并行搜索。其核心的“差分变异”策略，利用种群中不同个体间的向量差异来产生新的探索方向，赋予了算法强大的全局探索能力和跳出局部最优（包括“平坦”区域）的能力，从而确保了模型能够找到真正有意义的全局最优解。

综上所述，差分进化算法的各项核心优势与本问题的求解难点一一对应，是解决此类复杂优化问题的理想选择。

6.3.2 差分进化求解方案

参数向量定义 首先，我们将问题的决策变量，即 3 个 BMI 分组临界点 (b_1, b_2, b_3) 和 4 个分组对应的推荐 NIPT 时点 (t_1, t_2, t_3, t_4) ，定义为一个七维的实数参数向量。此向量构成差分进化算法中的一个“个体”，代表了一个完整的潜在解决方案。

风险函数评估 其次，我们构建了模型的风险函数（即目标函数），用于评估每个参数向量的优劣程度。该函数严格遵循我们在模型中建立的逻辑：

1. 接收一个参数向量作为输入。
2. 检验其是否满足基本约束（如 $20 \leq b_1 < b_2 < b_3 \leq 50$ ）和我们为确保持逻辑正确性而引入的单调性约束（ $t_1 \leq t_2 \leq t_3 \leq t_4$ ），若不满足则给予极大惩罚。
3. 根据临界点 (b_1, b_2, b_3) 对全体孕妇数据进行动态分组。
4. 对每个分组，基于其推荐时点 t_j ，计算两项核心成本：

时间风险成本：采用分段式的非线性 $time_cost(t)$ 函数，精确反映题干中提及的早、中、晚期发现的不同风险等级。

浓度不达标惩罚：将分组人群的 BMI 值和推荐时点 t_j 代入我们在第一问中已验证的全局线性回归模型，计算预测浓度，并利用合页损失函数量化其低于 4% 阈值的风险。

5. 将所有组的上述两项成本加权求和，得到该参数向量对应的总风险值。总风险值越小，代表方案越优。

差分进化过程 我们采用差分进化算法来求解此优化问题，因为它不依赖梯度信息，非常适合处理我们模型中因分组而产生的非平滑目标函数。算法从一个在可行域内随机生成的初始种群开始，通过迭代执行核心算子来寻找最优解：

- **变异 (Mutation)：**通过种群中其他个体的向量差分来生成一个扰动向量，为种群探索新方向提供动力。在本情境下，该操作通过组合现有策略的差异，来创建一个全新的“BMI 分组与 NIPT 时点”的候选方案。
- **重组 (Recombination)：**将变异向量与原个体向量的参数进行交叉混合，生成一个“试验向量”，以增加解的潜在多样性。在本情境下，该操作将新产生的候选方案与现有的优秀方案进行参数融合，以期“取长补短”，形成一个更优的改良策略。
- **选择 (Selection)：**采用“贪婪”策略，比较试验向量与原个体向量的风险函数值。在本情境下，这意味着每一个新产生的改良策略都必须经过我们风险函数的严格检验，只有当它能比原策略更有效地降低全体孕妇的总风险时才会被采纳，从而驱动解的质量不断提升。

经过多代进化，种群将收敛于全局最优区域。最终，种群中风险值最低的那个参数向量，即为我们求得的最优解^[7]。

6.3.3 求解结果

模型最终输出一套完整、针对不同 BMI 孕妇群体的 NIPT 检测策略, 如图6所示:

1. **最优 BMI 分组方案:** 我们得到了一组最优的 BMI 临界点, 它将所有孕妇划分为四个风险等级不同的群体。
2. **各组对应的最佳 NIPT 时点:** 针对上述每个 BMI 分组, 模型给出了一个对应的最佳检测孕周 t_j^* 。

表 6 最优 BMI 分组及对应的最佳 NIPT 时点方案

分组	孕妇 BMI 区间	最佳时点(周)	换算为周+天
第一组	[20.00, 29.07]	10.45	10 周 4 天
第二组	(29.07, 35.15]	12.00	12 周 0 天
第三组	(35.15, 36.13]	20.90	21 周 0 天
第四组	(36.13, 50.00]	24.73	24 周 6 天




图 6 不同组别建议孕检时间

求解该优化模型的完整计算流程, 已通过伪代码的形式在算法 1 中详细阐述。

Algorithm 1: 最优 BMI 分组参数 A^* 的数值求解算法

输入: 原始检测数据; 风险惩罚系数 λ ;

全局优化器参数 (搜索空间边界 bounds, 种群大小, 收敛阈值等)

输出: 最优的 BMI 分组边界 (b_1^*, b_2^*, b_3^*);

最优的推荐孕检时点 ($t_1^*, t_2^*, t_3^*, t_4^*$);

// Step 1: 数据加载与预处理

1 尝试读取 Excel 文件获取男胎检测数据 D ;

2 **if** 文件存在 **then**

3 定义数值列集合 C_{num} (取均值), 非数值列集合 C_{first} (取首个值);

4 构造聚合字典 agg_dict;

5 按“孕妇代码, 检测抽血次数”分组并聚合, 得到 D_{cleaned} ;

6 将“检测孕周”列由字符串 (如 12w + 3) 转换为浮点数;

7 重命名 Y 染色体浓度 $\rightarrow y_concentration$; 孕妇 BMI $\rightarrow bmi$;

8 筛选 $20 \leq bmi \leq 50$ 且孕周非空, 得到最终数据集 D_{filtered} ;

9 **end**

```

    // Step 2: 定义时间风险函数
1  for 孕周 $t$  do
2      if 孕周小于 12, 返回低风险参数;
3      if 在 12 到 28 之间, 返回中风险参数;
4      if 大于 28, 返回高风险参数;
5  end

    // Step 3: 定义目标函数
6  for 给定参数 $(b_1, b_2, b_3, t_1, t_2, t_3, t_4)$  do
7      if 不满足约束条件 then
8          返回  $+\infty$  (无效解)
9      按  $b_1, b_2, b_3$  将  $D_{\text{filtered}}$  分为四组  $G_1, \dots, G_4$ ;
10     for 每个组 $G_j$  do
11         设推荐孕周为  $t_j$ ;
12          $R \leftarrow R + |G_j| \cdot \text{time\_cost}(t_j)$ ;
13         计算预测值  $\hat{y} = 0.0022t_j - 0.0036 \cdot \text{bmi} + 0.12$ ;
14         计算 hinge 损失  $H = \max(0, 0.04 - \hat{y})$ ;
15          $R \leftarrow R + \lambda \cdot \sum H$ ;
16     end
17     返回  $R$ ;
18 end

    // Step 4: 全局优化
19 使用差分进化算法 differential_evolution 最小化目标函数;
20 if 优化成功 then
21     提取最优参数  $(b_1^*, b_2^*, b_3^*, t_1^*, t_2^*, t_3^*, t_4^*)$ ;
22     输出最优分组区间与对应推荐孕周;
23     统计各组人数并输出;
24 end

25 return  $(b_1^*, b_2^*, b_3^*, t_1^*, t_2^*, t_3^*, t_4^*, O_{\min})$ ;

```

七、问题三的模型的建立和求解

7.1 模型分析

为响应问题三需“综合考虑多种因素”的要求，我们首先将问题二中使用的简单二元模型，升级为一个更精准、更全面的多因素预测模型。我们首先通过方差膨胀因子 (VIF) 检验，诊断并解决了多因素间的共线性问题^[8]。基于最终筛选出的核心影响因素，我们同时建立了一个稳健的全局多元线性回归模型。

7.1.1 基于 VIF 检验的多重共线性诊断

模型原理 在多元线性回归中，多重共线性是指自变量之间存在高度相关关系，这会使得模型参数的估计变得不稳定，降低模型的可解释性。方差膨胀因子是衡量多重共线性严重程度的常用指标。对于给定的第 i 个自变量 X_i ，其 VIF 值计算公式为：

$$\text{VIF}_i = \frac{1}{1 - R_i^2} \quad (7)$$

其中， R_i^2 是将自变量 X_i 作为因变量，其余所有自变量 ($X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_p$) 作为自变量进行线性回归时得到的决定系数。VIF 值越大，表明 X_i 与其他自变量的线性关系越强。

在本研究中的应用与结果 我们将数据集中的连续型变量纳入 VIF 检验。计算结果显示，孕妇 BMI 指标 (X_{bmi}) 的 VIF 值高达 372.3，远超阈值 10，表明其与身高 (X_{height}) 和体重 (X_{weight}) 存在严重的线性重叠。为保证后续模型训练的稳定性及特征重要性评估的可靠性，我们在预测模型中剔除 BMI 指标，保留其原始构成变量身高和体重。

7.1.2 基于 XGBoost 与 SHAP 的特征重要性评估

XGBoost 回归模型 为精准拟合 Y 染色体浓度与众多影响因素间的复杂非线性关系，本研究采用极限梯度提升回归模型^[9]。XGBoost 是一种基于决策树的集成学习算法，它通过迭代地添加新的决策树来不断修正前一轮的预测残差。其最终的预测模型可表示为 K 棵树的加性模型：

$$\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F} \quad (8)$$

其中， $\hat{y}_i$ 是对第 i 个样本的 Y 染色体浓度的预测值， $\mathbf{x}_i$ 是其特征向量， f_k 代表第 k 棵决策树模型。 $\mathcal{F}$ 是所有可能决策树组成的函数空间。我们采用 80% 的数据作为训练集，20% 作为测试集，并设定树的数量为 200，学习率为 0.05，以构建稳健的预测模型。

SHAP 可解释性分析 为解释 XGBoost 这一“黑箱模型”的决策过程，并量化各特征的贡献，本研究采用 SHAP (SHapley Additive exPlanations) 方法。SHAP 植根于合作博弈论中的 Shapley 值，能够将模型的单个预测值解释为一个基准值（所有样本预测的平均值）与各个特征归因值之和^[10]。对于第 j 个特征的 SHAP 值 ϕ_j 的计算公式为：

$$\phi_j(\mathbf{x}) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(M - |S| - 1)!}{M!} [v(S \cup \{j\}) - v(S)] \quad (9)$$

其中， F 是所有特征的集合， M 是特征总数， S 是 F 中不包含特征 j 的一个子集。 $v(S)$ 表示仅使用特征子集 S 时模型的预测输出。该公式计算了特征 j 在所有可能的特征组合中的边际贡献的加权平均。

特征筛选结果 我们在测试集上计算了每个特征的 SHAP 值，并取其绝对值的均值 (Mean |SHAP|) 作为衡量该特征全局重要性的指标。结果如图7所示，排名前五的特征（抽血次数、体重、孕周、年龄、身高）的累积贡献率达到了 90.2%。这表明这五个因素是影响 Y 染色体浓度的最关键驱动力。因此，本研究选择这五个特征作为后续建立时点优化模型的核心自变量。




图 7 各影响因子相对贡献分析

7.2 模型建立

为满足问题三中多因素、检测误差及达标比例的新要求，我们将问题二的确定性优化模型升级为一个更精密的随机优化模型。其核心升级在于将风险控制从目标函数的“软惩罚”转变为模型的“硬约束”：我们引入概率约束来量化检测误差，并采用分位数决策来确保群体达标率。在此约束框架下，模型的优化目标得以简化为最小化全体孕妇的平均推荐 NIPT 时点，其决策变量仅为最优分组参数 $\mathbf{A}^*$ ，而各组的最佳时点 T_j^* 则由最优分组方案内生决定。

为简化表达，我们首先定义个体 i 的自变量向量 $\mathbf{X}_i$ 和第 j 组对应的系数向量 β_j ：

$$\begin{aligned} \mathbf{X}_i &= (1, X_{i,\text{week}}, X_{i,\text{weight}}, X_{i,\text{height}}, X_{i,\text{age}}, X_{i,\text{blood_draw_count}})^T \\ \beta_j &= (\beta_{0,j}, \beta_{1,j}, \beta_{2,j}, \beta_{3,j}, \beta_{4,j}, \beta_{5,j})^T \end{aligned}$$

因此，线性预测部分可以简洁地表示为 $\mathbf{X}_i^T \boldsymbol{\beta}_j$ 。该升级后模型的数学范式如下：

$$\begin{aligned} \min_{\mathbf{A} \in \mathbb{R}_+^3} \quad & \frac{1}{N} \sum_{j=1}^4 \sum_{i \in G_j(\mathbf{A})} T_j(\mathbf{A}) \\ \text{s.t.} \quad & \begin{cases} \mathbf{B}_j(\mathbf{A}), \sigma_j = \arg \min_{\boldsymbol{\beta}_j, \sigma_j} \sum_{i \in G_j(\mathbf{A})} (Y_i - \mathbf{X}_i^T \boldsymbol{\beta}_j)^2, \quad \forall j \\ X_{\text{week},i}^*(\mathbf{A}) = f_{\text{week}}^{\text{prob}}(\mathbf{X}_{i,\text{other}}; \mathbf{B}_j(\mathbf{A}), \sigma_j), \quad \forall i \in G_j(\mathbf{A}) \\ T_j(\mathbf{A}) = \text{Quantile}(\{X_{\text{week},i}^*(\mathbf{A})\}_{i \in G_j(\mathbf{A})}, q), \quad \forall j \\ \mathbf{A} \in \mathbb{R}_+^3 \end{cases} \end{aligned} \quad (10)$$

where:

- $G_j(\mathbf{A})$ 是分组集合，由参数向量 $\mathbf{A}$ 定义：

$$\begin{cases} G_1(\mathbf{A}) = \{i \mid X_{i,\text{bmi}} < 18.5 + \alpha_1\} \\ G_2(\mathbf{A}) = \{i \mid 18.5 + \alpha_1 \leq X_{i,\text{bmi}} < 24.0 + \alpha_2\} \\ G_3(\mathbf{A}) = \{i \mid 24.0 + \alpha_2 \leq X_{i,\text{bmi}} < 28.0 + \alpha_3\} \\ G_4(\mathbf{A}) = \{i \mid X_{i,\text{bmi}} \geq 28.0 + \alpha_3\} \end{cases} \quad (11)$$

- $\mathbf{B}_j(\mathbf{A})$ 与 σ_j 分别为分层回归模型的系数向量与残差标准差，模型形式为：

$$Y \approx \beta_{0,j} + \beta_{1,j} X_{\text{week}} + \beta_{2,j} X_{\text{weight}} + \beta_{3,j} X_{\text{height}} + \beta_{4,j} X_{\text{age}} + \beta_{5,j} X_{\text{blood_draw_count}} \quad (12)$$

- $f_{\text{week}}^{\text{prob}}(\cdot)$ 是考虑检测误差的个体最优孕周解析解，其推导基于概率约束 $P(Y_i \geq C_{\text{thresh}}) \geq p$ ，最终形式为：

$$\begin{aligned} f_{\text{week}}^{\text{prob}}(X_{i,\text{weight}}, X_{i,\text{height}}, X_{i,\text{age}}, X_{i,\text{blood_draw_count}}; \mathbf{B}_j(\mathbf{A}), \sigma_j) = \\ \frac{(C_{\text{thresh}} - z_{1-p} \sigma_j) - (\beta_{0,j} + \beta_{2,j} X_{i,\text{weight}} + \beta_{3,j} X_{i,\text{height}} + \beta_{4,j} X_{i,\text{age}} + \beta_{5,j} X_{i,\text{blood_draw_count}})}{\beta_{1,j}} \end{aligned} \quad (13)$$

其中， $X_{i,\text{weight}}, X_{i,\text{height}}, X_{i,\text{age}}, X_{i,\text{blood_draw_count}}$ 代表个体 i 的除孕周外的其他核心影响因素。

- $T_j(\mathbf{A})$ 是为第 j 组推荐的 NIPT 时点，通过计算该组所有个体最优孕周 $\{X_{\text{week},i}^*\}$ 的 q 分位数得到：

$$T_j(\mathbf{A}) = \text{Quantile}(\{X_{\text{week},i}^*(\mathbf{A})\}_{i \in G_j(\mathbf{A})}, q) \quad (14)$$

上述计算中涉及相较于问题二有改动的核心函数和参数定义如下：

分层回归系数向量 $B_j(\mathbf{A})$ 和残差标准差 σ_j ：这是第 j 组的预测模型参数。对于由特定参数 $\mathbf{A}$ 划分出的每一个孕妇分组 $G_j(\mathbf{A})$ ，模型都会使用该组内的所有数据，通过普通最小二乘法（OLS）拟合一个独立的多元线性回归模型。该模型形式为 $Y \approx \beta_{0,j} + \beta_{1,j}X_{\text{week}} + \beta_{2,j}X_{\text{weight}} + \beta_{3,j}X_{\text{height}} + \beta_{4,j}X_{\text{age}} + \beta_{5,j}X_{\text{blood_draw_count}}$ ，其中自变量是经过 VIF 和 SHAP 筛选出的核心影响因素。公式所求解的，正是这个模型中的系数向量 $\mathbf{B}_j = (\beta_{0,j}, \beta_{1,j}, \beta_{2,j}, \beta_{3,j}, \beta_{4,j}, \beta_{5,j})$ 以及模型的残差标准差 σ_j 。 σ_j 用于量化模型预测的不确定性或检测误差，是后续概率约束的关键参数。

考虑检测误差的个体最优孕周求解函数 $f_{\text{week}}^{\text{prob}}(\cdot)$ ：该函数用于计算在考虑检测误差的情况下，个体 i 能够以至少 p 的概率达到 Y 染色体浓度临床阈值 C_{thresh} 的最早 NIPT 孕周 $X_{\text{week},i}^*$ 。它将问题二中确定性的阈值约束升级为概率约束，更符合实际临床情况。其详细推导过程如下：

1. 首先，建立概率约束问题： $P(Y_i \geq C_{\text{thresh}}) \geq p$ 。
2. 假设误差服从正态分布 $Y_i \sim N(\hat{Y}_i, \sigma_j^2)$ ，其中 $\hat{Y}_i = \beta_{0,j} + \beta_{1,j}X_{\text{week}} + \beta_{2,j}X_{\text{weight}} + \beta_{3,j}X_{\text{height}} + \beta_{4,j}X_{\text{age}} + \beta_{5,j}X_{\text{blood_draw_count}}$ 是基于多因素回归模型的预测值。对不等式进行标准化：

$$P\left(\frac{Y_i - \hat{Y}_i}{\sigma_j} \geq \frac{C_{\text{thresh}} - \hat{Y}_i}{\sigma_j}\right) \geq p$$

3. 利用标准正态分布的累积分布函数 $\Phi(z)$ 进行转换，可得：

$$1 - \Phi\left(\frac{C_{\text{thresh}} - \hat{Y}_i}{\sigma_j}\right) \geq p \implies \Phi\left(\frac{C_{\text{thresh}} - \hat{Y}_i}{\sigma_j}\right) \leq 1 - p$$

这意味着 $\frac{C_{\text{thresh}} - \hat{Y}_i}{\sigma_j} \leq z_{1-p}$ ，其中 z_{1-p} 是标准正态分布的 $1 - p$ 分位数。进一步推导得到： $\hat{Y}_i \geq C_{\text{thresh}} - z_{1-p}\sigma_j$ 。

4. 将 $\hat{Y}_i$ 的表达式代入上式并求解 X_{week} ，即可得到最终的解析解：

$$\beta_{0,j} + \beta_{1,j}X_{\text{week}} + \beta_{2,j}X_{\text{weight}} + \beta_{3,j}X_{\text{height}} + \beta_{4,j}X_{\text{age}} + \beta_{5,j}X_{\text{blood_draw_count}} \geq C_{\text{thresh}} - z_{1-p}\sigma_j$$

由于孕周与 Y 染色体浓度正相关， $\beta_{1,j} > 0$ ，因此：

$$X_{\text{week}} \geq \frac{(C_{\text{thresh}} - z_{1-p}\sigma_j) - (\beta_{0,j} + \beta_{2,j}X_{\text{weight}} + \beta_{3,j}X_{\text{height}} + \beta_{4,j}X_{\text{age}} + \beta_{5,j}X_{\text{blood_draw_count}})}{\beta_{1,j}}$$

为最小化孕周，取其下界，即得到 $f_{\text{week}}^{\text{prob}}(\cdot)$ 的表达式。

组别推荐 NIPT 时点 $T_j(\mathbf{A})$ ：这是为第 j 组孕妇统一推荐的 NIPT 时点。它通过计算该组内所有个体最优孕周 $\{X_{\text{week},i}^*(\mathbf{A})\}_{i \in G_j(\mathbf{A})}$ 的 q 分位数来确定。采用分位数确保组内至少有 q 比例的孕妇能够在其推荐时点进行 NIPT 时，满足 Y 染色体浓度达标的概率要求。

7.3 模型求解

问题三在问题二的基础上，引入了多因素预测、检测误差的概率考量以及达标比例的群体要求，使得模型内部的计算逻辑更为复杂和精细。然而，从优化问题的宏观结构来看，其本质依然是一个涉及非光滑、不可微且非凸目标函数的双层优化问题。因此，问题二中关于遗传算法（GA）适用性的分析依然成立，并且由于问题三的内部计算复杂性增加，DE 作为一种鲁棒的全局优化算法，其必要性反而进一步凸显。

7.3.1 差分进化算法求解方案

问题三的求解框架延续了问题二的核心思想，即通过优化 BMI 分组临界点来寻找全局最优的 NIPT 时点策略。然而，为满足问题三更复杂的现实约束（多因素影响、检测误差、达标比例），我们对模型的内部逻辑和求解算法进行了全面的重构与深化。算法层面，我们依旧采用差分进化算法；模型层面，决策变量、评估函数和优化目标均有显著升级。

决策变量的简化 与问题二同时优化 7 个变量（3 个分割点和 4 个推荐时点）不同，问题三的模型设计更为精妙。我们认识到，在一个给定的分组方案下，最优的推荐时点 T_j 应由该组的数据特性（结合概率约束和达标比例）**计算得出**，而非一个独立的、需要优化的自由变量。因此，优化算法的核心决策变量被简化为 3 个 BMI 分组临界点 $\mathbf{B} = (b_1, b_2, b_3)$ ：

$$\text{优化参数向量} = [b_1, b_2, b_3]$$

这一改变使得优化目标更纯粹，完全聚焦于寻找“最佳的分组方案”。

风险函数评估的重构 每个参数向量的优劣由其对应的风险函数值（即最小平均推荐孕周）决定。评估过程是算法的核心，它将问题三复杂的约束内化为一个函数。相较于问题二，其内部逻辑进行了以下三项关键的重构升级：

- 一：从“确定性”到“概率性”的个体孕周计算

问题二中，个体孕周是基于一个简单的确定性公式计算的。在问题三中，我们利用全局模型的残差标准差 σ_{global} 作为“检测误差”的量化指标，并引入个体达标置信水平 p （例如 95%）。基于概率约束 $P(Y_i \geq C_{\text{thresh}}) \geq p$ ，我们为每个个体 i 推导并计算出其达标的、考虑了不确定性的最早孕周 $X_{\text{week},i}^*$ 。

- 二：从“惩罚项”到“分位数”的组别时点确定

问题二通过在目标函数中设置惩罚项来降低风险。问题三则将风险控制前置：我们引入组内达标比例 q （例如 90%），将一个分组 j 的最终推荐时点 T_j 定义为该组所有个体孕周 $\{X_{\text{week},i}^*\}$ 的 q **分位数**。这意味着，在该推荐时点进行检测，组内至少有 q 比例的孕妇能满足其个体概率达标要求，从而将“达标比例”这一硬性要求内化到了模型约束中。

• 三：从“复合风险”到“单一目标”的优化

由于风险控制已通过概率约束和分位数定义融入计算过程，问题三的优化目标变得更为纯粹和明确：即最小化全体孕妇的平均推荐 NIPT 时点

$$\frac{1}{N} \sum_{j=1}^4 n_j T_j.$$

进化过程 差分进化算法的原理是通过迭代改善一个由候选解（参数向量）组成的种群。其进化过程（变异、重组、选择）与问题二的优化思想一致，但其强大的全局搜索能力使它能有效应对由分组计算导致的、目标函数非光滑的挑战，确保找到全局最优的分组参数 B^* 。

7.3.2 求解结果

模型的最终输出是一套双层、且逻辑自洽的 NIPT 检测策略：

表 7 最优 BMI 分组及对应的最佳 NIPT 时点方案

分组	孕妇 BMI 区间	最佳时点 (周)	换算为周 + 天 (向上取整)
第一组	[20.00, 31.15]	11.25	11 周 2 天
第二组	(31.15, 34.12]	12.00	12 周 0 天
第三组	(34.12, 41.37]	17.50	17 周 4 天
第四组	(41.37, 50.00]	23.14	23 周 1 天

八、问题四的模型的建立和求解

8.1 模型分析

8.1.1 模型目标与核心问题

女性胎儿 NIPT 检测因缺乏 Y 染色体标志物而导致准确性受限，是临床的一大挑战。鉴于传统的单 Z 值阈值法存在局限，本研究旨在超越单一指标，通过构建一个整合了多维生物学与临床特征（如多染色体 Z 值、BMI 等）的非线性支持向量机（SVM）分类模型，以显著提升对常见非整倍体的预测能力，为临床决策提供更稳健的支持。

8.1.2 数据探索与预处理

数据集概览 本分析基于‘女胎检测数据.csv’数据集，其中包含女性胎儿的匿名 NIPT 结果记录，数据如图 8所示。该数据集包括多种可能与预测染色体异常相关的特征。

- 1. 目标变量: 主要的结果变量是染色体的非整倍体，它指明了检测到的特定非整倍体类型（如 T21、T18、T13），或在正常情况下为空值。
- 2. 预测变量: 用于预测模型的关键特征包括：

母体因素: 年龄、孕妇 BMI。

测序质量指标: GC 含量、唯一比对的读段数。

染色体 Z 值: 13 号染色体的 Z 值、18 号染色体的 Z 值、21 号染色体的 Z 值、X 染色体的 Z 值。

探索性数据分析 (EDA)

1. 目标变量分布 对目标变量的初步分析显示出明显的类别不平衡，这在临床筛查环境中是预料之中的，因为异常情况相对罕见。

表 8 女性胎儿数据集中非整倍体类型的分布

Abnormality Type	Count	Percentage
Normal	573	92.42%
T21	21	3.39%
T18	17	2.74%
T13	6	0.97%
T13T21	2	0.32%
T18T21	1	0.16%
Total	620	100.00%




图 8 女性胎儿非整倍体分布

目标变量的分布呈现出严重的偏态，其中“正常”类别占据了 92.42% 的绝对多数。这种数据结构引出了所谓的“准确率悖论”：一个最简单的分类器，若将所有样本均预测为“正常”，其准确率便能轻易超过 92%。显然，该准确率无法体现模型对少数类（即各类非整倍体）的任何有效预测能力。为规避此评估陷阱，并真实度量模型的诊断价值，后续的模型性能评估将摒弃传统的准确率，转而采用一系列对类别不平衡更具鲁棒性的指标，包括精确率、召回率和 F1 分数。

2. 预测变量描述性统计分析 为掌握各数值型预测变量的统计特性，我们计算了其描述性统计量，结果如表9所示。

表 9 关键预测变量的描述性统计

特征	均值	标准差	最小值	25% 分位数	50% 分位数	75% 分位数	最大值
年龄 (Age)	31.05	4.67	19.00	28.00	31.00	34.00	46.00
孕妇 BMI (BMI)	24.58	4.61	15.62	21.22	23.88	27.24	46.88
GC 含量 (GC Content)	0.400	0.005	0.385	0.397	0.400	0.403	0.428
13 号染色体 Z 值	0.42	2.21	-3.85	-0.47	0.13	0.94	29.35
18 号染色体 Z 值	0.73	3.63	-3.96	-0.37	0.41	1.34	38.69
21 号染色体 Z 值	0.94	4.13	-4.58	-0.42	0.28	1.37	31.62
X 染色体 Z 值	-0.10	1.83	-10.27	-0.96	-0.06	0.81	13.91




图 9 关键预测变量的描述统计

13、18 和 21 号染色体的 Z 值范围很广，且存在显著的正向异常值，这表明数据集中存在具有极高 Z 值的非整倍体样本。

3. 对比分析：正常与非整倍体案例 为了识别最具区分性的特征，我们比较了正常组与各非整倍体组之间的特征分布。

- **21 三体综合征 (T21):** 最显著的差异在于 21 号染色体的 Z 值。T21 病例的中位 Z 值为 **13.08**，而正常病例为 **0.22**。这一巨大差异经独立 t 检验确认 (p 值 < 0.001)，表明 Z-score_21 是唐氏综合征的强有力预测指标。
- **18 三体综合征 (T18):** 同样，T18 病例中 18 号染色体的中位 Z 值为 **12.44**，而正常病例为 **0.36** (p 值 < 0.001)。这证实了其对爱德华兹综合征的高预测价值。
- **13 三体综合征 (T13):** T13 病例中 13 号染色体的中位 Z 值为 **12.18**，而正常病例为 **0.10** (p 值 < 0.001)，表明其对帕陶氏综合征具有很强的区分能力。
- **其他特征 (BMI, GC 含量):** 虽然像 BMI 和 GC 含量等其他一些特征在正常组和非整倍体组之间也存在统计学上的显著差异，但这些差异的幅度远小于 Z 值的差异。这表明它们可能作为次要或调节因素，而非主要指标。

该探索性分析证实，染色体 Z 值是构建分类模型最有希望的特征。这些特定标记在正常和异常组之间的明显分离，验证了 NIPT 的基本原理。

8.1.3 支持向量机 (SVM) 分类模型框架

为解决该分类问题，我们构建了支持向量机 (SVM) 模型，因其尤其擅长处理 NIPT 数据这种高维、复杂的分类任务。该模型的核心是在多维特征空间中寻找一个能最大化类别间隔的最优超平面，并通过核技巧（特别是 RBF 核）将数据映射至更高维度，以有效处理非线性关系^[11]。

8.2 模型建立

在实际的生物医学数据分析中，各项诊断指标与最终诊断结果之间的关系往往是复杂的、非线性的。传统的线性模型可能难以有效捕捉这些细微的模式。为了提升分类的准确性并增强模型的表达能力，我们采用非线性支持向量机模型，该模型通过引入“核技巧”来应对这一挑战。

核技巧的核心思想是通过一个非线性映射函数 $\phi(\cdot)$ ，将原始的 d 维特征向量 $\mathbf{x} \in \mathbb{R}^d$ 映射到一个更高维甚至无限维的特征空间 $\mathcal{H}$ 。其精妙之处在于，在这个高维空间中，原本在原始空间中线性不可分的样本数据可能变得线性可分。更重要的是，我们无需显式地定义或计算这个复杂的映射函数 $\phi(\mathbf{x})$ ，而是通过核函数 $K(\mathbf{x}_i, \mathbf{x}_j)$ ，直接计算任意两个样本点 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 在高维特征空间中的内积：

$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

这种方法极大地简化了计算，使得在高维空间中学习非线性决策边界成为可能。

在本研究中，我们选用径向基函数核，因为它在处理复杂的非线性生物学数据时表现出色，具有很强的灵活性和良好的泛化能力。RBF 核函数定义如下：

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad \gamma > 0$$

其中， $\|\mathbf{x}_i - \mathbf{x}_j\|^2$ 是两个样本点（例如，两位孕妇）的特征向量在欧氏空间中距离的平方，反映了它们在生物学指标上的差异程度。 γ 是一个关键的超参数，它决定了单个训练样本影响范围的大小。

结合核技巧，软间隔 SVM 的目标是在高维特征空间中找到一个能最大化类别间隔的超平面。为了求解此问题，我们通常关注其对偶形式，因为它直接引入了核函数，避免了与高维空间向量 $\mathbf{w}$ 和映射 $\phi(\cdot)$ 的直接计算。其原始和对偶问题表述为：

$$\begin{aligned} \underset{\mathbf{w}, b, \xi}{\text{minimize}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \\ \text{subject to} \quad & y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N, \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned} \quad (15)$$

$$\begin{aligned} \underset{\alpha}{\text{maximize}} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \\ \text{subject to} \quad & \sum_{i=1}^N \alpha_i y_i = 0, \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{aligned} \quad (16)$$

这里各项的含义与生物学背景解释如下：

- **训练数据:** $(\mathbf{x}_i, y_i)$ 代表第 i 位孕妇的数据。 $\mathbf{x}_i \in \mathbb{R}^d$ 是该孕妇的 d 维生物学特征向量（包含各染色体 Z 值、BMI 等指标）。 y_i 是其真实的临床诊断标签。由于本研究涉及多个类别，例如 $y_i \in \{\text{正常}, \text{T21}, \text{T18}, \text{T13}\}$ ，我们将采用“一对多”策略将多分类问题分解为多个二分类子问题进行处理。在每个子问题中， $y_i \in \{+1, -1\}$ 。
- **目标函数:** 该函数通过优化拉格朗日乘子 α_i 来求解。其目标是在满足约束的条件下，找到能使高维空间中间隔最大化的解。核函数 $K(\mathbf{x}_i, \mathbf{x}_j)$ 在此取代了原始的内积，用于衡量样本在高维空间中的相似性。
- **约束条件:**
 - $\sum_{i=1}^N \alpha_i y_i = 0$: 这是一个确保解的有效性的平衡约束。
 - $0 \leq \alpha_i \leq C$: 此约束将每个拉格朗日乘子 α_i 限制在一个盒子范围内。参数 $C > 0$ 是惩罚系数。它控制着模型在结构风险和经验风险之间的权衡。

- **支持向量**: 在完成模型训练后, 那些对应拉格朗日乘子 $\alpha_i > 0$ 的训练样本点被称为支持向量。它们是定义最终决策边界的关键数据点。

对于一个新的、待诊断的样本 $\mathbf{x}_{\text{new}}$, 其类别通过以下决策函数来判定:

$$f(\mathbf{x}_{\text{new}}) = \text{sign} \left(\sum_{i \in \text{SV}} \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_{\text{new}}) + b^* \right)$$

其中, SV 是支持向量的集合, b^* 是通过优化得到的偏置项。这个决策过程的几何意义是, 判断新样本的特征向量 $\mathbf{x}_{\text{new}}$ 在映射到高维空间后, 落在了由最优决策边界所划分的哪一侧。在多分类场景下, 最终的诊断结果将由所有二元分类器的预测结果组合决定。

8.3 模型求解

建模方法与流程 本研究旨在构建一个支持向量机分类器 $f(\mathbf{x})$, 以预测 NIPT 样本的非整倍体状态 y 。初始数据集 $\mathcal{D}$ 包含 $N = 589$ 个样本, 每个样本 $\mathbf{x}_i$ 对应一个 $d = 9$ 维的特征向量, 其标签 $y_i \in \{\text{Normal}, \text{T13}, \text{T18}, \text{T21}\}$ 。数据预处理流程 Φ 包括目标变量编码、孕周特征数值化、样本类别筛选与数据清洗, 最终生成建模所需的特征矩阵 $\mathbf{X} \in \mathbb{R}^{N \times d}$ 和标签向量 $\mathbf{y} \in \mathbb{R}^N$ 。

我们将数据集 $\mathcal{D}$ 通过分层抽样划分为训练集 $\mathcal{D}_{\text{train}}$ ($N_{\text{train}} = 471$) 和测试集 $\mathcal{D}_{\text{test}}$ ($N_{\text{test}} = 118$)。为解决训练集中的类别不平衡问题, 我们采用 RandomOverSampler 技术对其进行过采样, 生成一个类别均衡的训练集 $\mathcal{D}'_{\text{train}}$ 。模型训练在一个包含标准化 (Z-score Normalization) 和 SVC 的 Pipeline 中进行。特征标准化遵循以下变换:

$$\mathbf{x}_{\text{std}} = \frac{\mathbf{x} - \boldsymbol{\mu}_{\text{train}}}{\boldsymbol{\sigma}_{\text{train}}}$$

其中 $\boldsymbol{\mu}_{\text{train}}$ 和 $\boldsymbol{\sigma}_{\text{train}}$ 分别为训练集 $\mathcal{D}_{\text{train}}$ 的特征均值和标准差向量。

模型超参数的寻优通过网格搜索完成, 其搜索空间 $\mathcal{H}$ 定义为:

- 正则化系数 $C \in \{10^{-2}, 10^{-1}, \dots, 10^3\}$
- 核函数类型 $\text{kernel} \in \{\text{rbf}, \text{linear}, \text{poly}\}$
- RBF 核系数 $\gamma \in \{\text{scale}, \text{auto}, 10^{-3}, \dots, 10^1\}$

我们采用 3 折交叉验证, 以宏平均 F1 分数 (F1-macro) 作为优化目标函数 $J(C, \text{kernel}, \gamma)$ 。最终确定的最优超参数组合 $(C^*, \text{kernel}^*, \gamma^*)$ 为 (100, rbf, scale)。

模型性能与结果分析 我们在独立的测试集 $\mathcal{D}_{\text{test}}$ 上对训练好的最优模型进行了全面评估，核心性能指标汇总于表10。

表 10 模型在独立测试集上的核心性能指标汇总

类别	样本数	精确率 (P)	召回率 (R)/敏感性	F1 分数	特异性
Normal	108	0.920	0.963	0.941	—
T13	2	0.000	0.000	0.000	0.991
T18	6	0.000	0.000	0.000	0.973
T21	2	0.000	0.000	0.000	0.991
整体准确率: 88.14%		平衡准确率: 24.07%		宏平均 F1: 23.53%	

评估结果清晰地揭示了模型的预测行为与性能特点：

- 1. **对正常样本的高识别能力：**模型在识别多数类 “Normal” 样本时表现出色，其 F1 分数达到了 0.941。这表明模型作为一个 “排阴” 工具是高效的。
- 2. **对异常样本的检测失效：**对于所有少数类 (T13, T18, T21)，模型的召回率（即临床上的敏感性）均为 0，这意味着模型未能成功检出任何一个异常样本。
- 3. **高特异性与低假阳性：**尽管敏感性为 0，但模型在所有异常类别上均表现出极高的特异性 (>97%)。这意味着模型极少会将正常样本误判为异常，假阳性率很低。

8.3.1 求解结果

基于支持向量机的 NIPT 女胎异常判定模型在测试集上的表现可以总结如下：

- 1. **正常样本识别能力强：**模型在识别正常样本方面表现优异，精确率达 92.04%，召回率达 96.30%，F1 分数为 94.12%，结果如图 10。这表明模型能够有效避免将正常胎儿误诊为异常。
- 2. **异常样本检测能力有限：**由于训练数据中异常样本极度稀少 (T13:8 个，T18:26 个，T21:7 个)，模型在检测具体异常类型方面存在明显不足，所有异常类别的敏感性均为 0。
- 3. **特异性表现良好：**各异常类别的特异性均超过 97%，说明模型在排除特定异常方面较为可靠，假阳性率较低。
- 4. **整体分类效果：**模型主要将所有样本都预测为正常类别，这在极度不平衡的数据集上是一种保守但理性的策略。


结论 本研究成功构建了基于支持向量机的 NIPT 女胎异常判定模型，该模型综合考虑了 X 染色体及 21 号、18 号、13 号染色体的 Z 值、GC 含量、读段数、BMI 等多个因素。尽管受到数据不平衡的限制，模型在正常样本识别方面表现出色，具有较高的特异性和阴性预测值。

该模型为解决 NIPT 女胎检测中的技术挑战提供了一种新的思路，即通过机器学习技术整合多维生物学信息来提高诊断准确性。虽然当前模型在异常检测方面仍有改进空间，但其框架和方法学为未来的研究奠定了基础。随着更多高质量数据的积累和算法的持续优化，该方法有望在临床实践中发挥更大的作用。

表 11 模型性能指标

性能指标	数值
整体准确率	88.14%
平衡准确率	24.07%
宏平均 F1 分数	23.53%
正常样本精确率	92.04%
正常样本召回率	96.30%
平均特异性	98.53%
最优超参数 C	100
最优超参数 γ	scale
最优核函数	RBF

图 10 模型性能评价



九、模型的分析与检验

为全面评估本研究中所建模型的稳健性与可靠性，本章将从灵敏度分析和误差分析两个维度对模型进行深入检验。灵敏度分析旨在探究模型输出对关键参数变化的敏感程度，而误差分析则致力于识别模型预测偏差的来源并评估其影响。

9.1 灵敏度分析

灵敏度分析通过系统性地调整模型中的关键参数，观测模型输出结果的变化，以评估模型的稳定性和对外部条件变化的依赖性。

1. 时点优化模型（问题二、三）的灵敏度分析

我们在问题二、三中构建的 NIPT 时点优化模型，其推荐策略高度依赖于几个核心的临床与模型参数。我们认为，模型的灵敏度主要体现在以下几个方面：

- **对临床阈值 C_{thresh} 的敏感性**：模型以 Y 染色体浓度达到 4% 为核心约束。这个阈值是决定推荐时点早晚的关键。可以预见，若临床标准放宽，模型推荐的检测时点将普遍提前；反之，若标准收紧，为保证达标率，推荐时点将显著推迟。模型结果对这一参数的变化是高度敏感的。
- **对风险偏好参数 p 和 q 的敏感性（问题三）**：提高个体达标置信水平 (p) 或群体达标比例 (q) 会使模型更趋保守，推荐更晚的检测时点以确保成功率。
- **对时间风险函数的敏感性（问题二）**：调整不同孕周的风险权重会改变模型的决策权衡，如增加晚期风险惩罚会迫使模型推荐更早的检测时点。

2. 女胎异常判定模型（问题四）的灵敏度分析

SVM 分类器的性能由超参数 C 和 γ 决定。我们通过网格搜索找到的最优解预计具有稳定性，即模型性能在最优参数的邻近区域内不会急剧下降，而是平滑变化。

9.2 误差分析

1. 预测模型（问题一及问题三基础）的误差来源

作为时点优化基础的线性回归模型，其误差主要源于两方面：

- **模型结构误差**：这是主要的误差来源。模型的 R^2 仅为 0.048，表明线性假设过于简化，未能捕捉 Y 染色体浓度变化的复杂非线性模式。
- **数据测量误差**：各输入变量的测量不精确性也会引入误差，尽管问题三模型对此有所考量。

2. 时点优化模型（问题二、三）的误差影响

上游预测模型的误差会直接传播，影响最终推荐时点的准确性。问题三的概率约束设计 ($P(Y_i \geq C_{\text{thresh}}) \geq p$) 通过增加安全边际，在一定程度上提升了决策对该误差的稳健性。

3. 女胎异常判定模型（问题四）的误差分析

SVM 模型的误差分布及其临床意义是分析的核心：

- **第二类误差（假阴性）**：模型对所有异常类别的召回率（敏感性）均为 0，无法检出任何异常样本，这是其在临床应用中最致命的缺陷。
- **第一类误差（假阳性）**：与之对应，模型的特异性极高 (>97%)，极少将正常样本误判为异常。

十、模型评价与展望

10.1 双层优化模型

为解决 NIPT 时点选择这一核心议题，我们采取了逐步求精的建模策略。我们首先在问题二中构建了一个概念性的基础模型，用于探索“BMI 分组—时点优化”的核心机制；随后，在问题三中，我们针对现实世界的复杂性，对该模型进行了全面的精化和升级，最终形成了一套鲁棒、高效且具有现实指导意义的决策框架。

10.1.1 模型优点

1. **双层优化模型：**我们从问题二的双因素探索性模型出发，搭建并验证了优化框架。在此基础上，问题三进一步引入多因素回归、概率约束和分位数决策。
2. **差分进化算法：**问题二、三的优化模型，其目标函数因动态数据分组而具有、非光滑与非凸的复杂特性，导致传统的梯度类算法无法适用。为此，我们选择了不依赖梯度的差分进化算法（DE）进行求解。
3. **求解算法的鲁棒性：**我们采用的差分进化算法确保了求解结果的鲁棒性。该算法通过维护一个解种群进行并行搜索，并利用个体间的差异向量进行变异，使其不易陷入局部最优“陷阱”。

10.1.2 模型不足与展望

1. **对线性关系的依赖：**构建的是多因素模型，但其核心是多元线性回归，假设 Y 染色体浓度与各影响因素之间存在线性关系。不适用于非线性模式。
2. **关键参数的设定：**模型中的关键概率参数，如个体达标置信水平 p 和组内达标比例 q （我们设为 95% 和 90%），是根据临床常规设定的超参数。
3. **数据样本的局限性：**本模型的所有结论均基于当前提供的男胎孕妇数据集。模型的有效性对于不同地区，有待更大规模、更多样化的数据进行进一步的验证和校准。

参考文献

- [1] 陈鹏宇, 张铨富. 无创产前检测中胎儿游离 DNA 浓度的影响因素及临床应用研究进展[J]. *Advances in Clinical Medicine*, 2024, 14:1182.
- [2] JAYASHANKAR S S, NASARUDDIN M L, HASSAN M F, et al. Non-invasive prenatal testing (nipt): reliability, challenges, and future directions[J]. *Diagnostics*, 2023, 13(15): 2570.
- [3] ZHANG J, WU Y, CHEN S, et al. Prospective prenatal cell-free dna screening for genetic conditions of heterogenous etiologies[J]. *Nature medicine*, 2024, 30(2):470-479.
- [4] 杨洁霞, 郭芳芳, 彭海山, 等. 无创产前基因检测技术在胎儿染色体非整倍体筛查中的应用研究[J]. *中国产前诊断杂志 (电子版)*, 2016.
- [5] KIMI. K1.5[J]. Kimi, 2025-9-5, Kimi:月之暗面.
- [6] 梁娟, 林征, 许红, 等. 二胎高龄妇女妊娠期需求量表的编制及信效度检验研究[J]. *中国全科医学*, 2018, 21(17):2097.
- [7] GEAR C W. Algorithm 407: Difsub for solution of ordinary differential equations [d2] [J]. *Communications of the ACM*, 1971, 14(3):185-190.
- [8] CHENG J, SUN J, YAO K, et al. A variable selection method based on mutual information and variance inflation factor[J]. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy*, 2022, 268:120652.
- [9] NIAZKAR M, MENAPACE A, BRENTAN B, et al. Applications of xgboost in water resources engineering: A systematic literature review (dec 2018–may 2023)[J]. *Environmental Modelling & Software*, 2024, 174:105971.
- [10] MOSCA E, SZIGETI F, TRAGIANNI S, et al. Shap-based explanation methods: a review for nlp interpretability[C]//*Proceedings of the 29th international conference on computational linguistics*. [S.l.: s.n.], 2022: 4593-4603.
- [11] YUE S, LI P, HAO P. Svm classification: Its contents and challenges[J]. *Applied Mathematics-A Journal of Chinese Universities*, 2003, 18(3):332-342.
- [12] 薛莹, 丁洁, 贺权泽, 等. 孕妇年龄, 孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响[J]. *中国产前诊断杂志 (电子版)*, 2017.

- [13] 葛淑娴. NIPT 检测罕见常染色体非整倍体及微缺失/微重复综合征的临床应用价值及影响因素[D/OL]. 河北医科大学, 2024. DOI: 10.27111/d.cnki.ghyku.2024.001752.
- [14] NHITA F, KURNIAWANI I, et al. Performance and statistical evaluation of three sampling approaches in handling binary imbalanced data sets[C]//2023 International Conference on Data Science and Its Applications (ICoDSA). [S.l.]: IEEE, 2023: 420-425.

附录 A 支撑材料

文件名	功能描述
Question1.py	问题一程序代码
Question1.py	问题二程序代码
Question3data.py	问题三数据处理代码
Question3opti.py	问题三程序优化代码
Question4.py	问题四程序代码
AI 使用详情	AI 使用详情

附录 B 程序重点源码

Question1.py

```
1  # 聚合规则
2  agg_rules = {col: 'mean' for col in num_cols}
3  for col in str_cols:
4      agg_rules[col] = 'first'
5  # 数据去重
6  clean_data = data.groupby(['孕妇代码', '检测抽血次数']).
agg(agg_rules).reset_index()
7
8  print(f"去重后剩余 {len(clean_data)} 条记录")
9  # 孕周格式转换
10 def parse_week(week_str):
11     try:
12         if isinstance(week_str, str) and 'w+' in week_str:
13             week, days = week_str.replace('w', '').split('
+ ')
14             return int(week) + int(days) / 7
15         elif isinstance(week_str, str) and 'w' in week_str
:
16             week = week_str.replace('w', '')
17             return float(week)
18     else:
19         return float(week_str)
```

```

20         except Exception:
21             return None
22
23     clean_data['week'] = clean_data['检测孕周'].apply(
parse_week)
24     # 列名重命名
25     clean_data.rename(columns={
26         'Y染色体浓度': 'y_conc',
27         '孕妇BMI': 'bmi'
28     }, inplace=True)
29     # 数据筛选
30     final_data = clean_data[
31         (clean_data['bmi'] >= 20) &
32         (clean_data['bmi'] <= 50) &
33         (clean_data['week'].notna())
34     ].copy()
35     print(f"筛选后用于分析的数据共 {len(final_data)} 条")
36     print("-" * 30)
37
38 else:
39     print("数据为空")
40     final_data = pd.DataFrame()
41     # 准备回归数据
42     X = final_data[['week', 'bmi']]
43     y = np.sqrt(final_data['y_conc'])
44     # 添加截距项
45     X = sm.add_constant(X)
46     # 建立回归模型
47     reg_model = sm.OLS(y, X).fit()
48     # 输出结果
49     print(reg_model.summary())
50     解释

```

Question2.py

```

1 #优化模型

```

```

2 from scipy.optimize import differential_evolution
3
4 def calc_time_cost(t, c1=10, c2=50):
5     """
6     根据题干定义的分段式、非线性的时间风险函数。
7     参数：
8     t (float): 孕周数
9     c1 (float): 进入高风险区(>12周)的惩罚常数
10    c2 (float): 进入极高风险区(>=28周)的惩罚常数
11    返回：
12    float: 风险调整后的时间成本
13    """
14    if t <= 12:
15        return t
16    elif 12 < t < 28:
17        return t + c1
18    else: # t >= 28
19        return t + c2
20
21 # 修正目标函数中的公式
22 def calc_objective(params, df, lambda_penalty):
23     """
24     目标函数，计算给定参数下的总风险。
25     """
26     b1, b2, b3, t1, t2, t3, t4 = params
27
28     # 强迫推荐时点必须随BMI分组递增
29     if not (t1 <= t2 <= t3 <= t4):
30         return float('inf')
31
32     if not (20 <= b1 < b2 < b3 <= 50) or not all(10 <= t <= 25
33     for t in [t1, t2, t3, t4]):
34         return float('inf')
35
36     bins = [20, b1, b2, b3, 50]

```

```

36     group_labels = ['Group1', 'Group2', 'Group3', 'Group4']
37     try:
38         df['group'] = pd.cut(df['bmi'], bins=bins, labels=
group_labels, right=True, include_lowest=True)
39     except ValueError:
40         return float('inf')
41
42     groups = df.groupby('group', observed=True)
43
44     total_week_sum = 0
45     risk_week_sum = 0
46     penalty_sum = 0
47
48     recommend_time_map = {'Group1': t1, 'Group2': t2, 'Group3'
: t3, 'Group4': t4}
49
50     for name, group_df in groups:
51         if group_df.empty:
52             continue
53
54         n_samples = len(group_df)
55         ti = recommend_time_map[name]
56
57         total_week_sum += n_samples * ti
58
59         risk_week_sum += n_samples * calc_time_cost(ti)
60         predicted_y = 0.0022 * ti - 0.0036 * group_df['bmi'] +
0.12
61
62         hinge_loss = np.maximum(0, 0.04 - predicted_y)
63         penalty_sum += hinge_loss.sum()
64
65     return risk_week_sum + lambda_penalty * penalty_sum
66
67 #求解优化

```

```

68 if not final_data.empty:
69     LAMBDA = 1000
70
71     bounds = [(20, 50), (20, 50), (20, 50), (10, 40), (10, 40)
72               , (10, 40), (10, 40)]
73
74     print("--- 开始运行全局优化（加入非线性时间风险） ---")
75     print("注意：模型现在会极力避免超过12周和28周...")
76
77     result = differential_evolution(
78         func=calc_objective,
79         bounds=bounds,
80         args=(final_data, LAMBDA),
81         strategy='best1bin',
82         popsize=15,
83         tol=0.01,
84         mutation=(0.5, 1),
85         recombination=0.7,
86         seed=42
87     )

```

Question3data.py

```

1  except Exception as e:
2      print(f"数据处理过程中发生错误：{e}")
3      model_data = pd.DataFrame()
4
5  # VIF检验与回归模型
6  if not model_data.empty:
7      try:
8          # VIF 检验
9          print("\n# VIF 检验（多重共线性诊断）")
10         X_vif = model_data[['gw', 'weight', 'height', 'age', '
11         blood_count']]
12         X_vif_const = sm.add_constant(X_vif)

```



```

13     vif_df = pd.DataFrame()
14     vif_df["feature"] = X_vif_const.columns
15     vif_df["VIF"] = [variance_inflation_factor(X_vif_const
16 .values, i) for i in range(X_vif_const.shape[1])]
17     print(vif_df)
18
19     # 选择最终变量
20     final_vars = ['gw', 'weight', 'age', 'blood_count']
21     print(f"\n# 已选定回归变量: {final_vars}")
22
23     # 建立回归模型
24     formula = f'y_conc ~ {" + ".join(final_vars)}'
25     ols_model = smf.ols(formula, data=model_data).fit()
26
27     # 模型结果输出
28     print("\n# 模型关键参数输出")
29
30     # 1. 残差标准差
31     sigma = np.sqrt(ols_model.mse_resid)
32     print(f"GLOBAL_SIGMA = {sigma:.8f}\n")
33
34     # 2. 回归系数
35     coeffs = ols_model.params.to_dict()
36     print("GLOBAL_COEFFS = {")
37     for key, val in coeffs.items():
38         print(f"    '{key}': {val:.8f},")
39     print("}\n")
40
41     print("# OLS 回归模型摘要")
42     print(ols_model.summary())
43
44 except Exception as e:
45     print(f"回归分析失败: {e}")
46
47 else:
48     print("数据为空，无法执行回归分析。")

```

Question3opti.py

```
1 # 优化模型超参数
2 MODEL_PARAMS = {
3     'p_confidence': 0.95, # 置信度 P
4     'q_proportion': 0.90, # 分位数 Q
5     'c_threshold': 0.04, # 浓度阈值 C
6     'min_week': 10      # 最小推荐孕周
7 }
8
9 # 环境设置
10 warnings.filterwarnings('ignore', category=FutureWarning)
11
12 # 函数定义区
13 def parse_gw(gw_str):
14     try:
15         if isinstance(gw_str, str) and 'w+' in gw_str:
16             week, days = gw_str.split('w+')
17             return int(week) + int(days) / 7
18         return float(gw_str)
19     except (ValueError, TypeError):
20         return np.nan
21
22 def get_blood_count(count_val):
23     if isinstance(count_val, str):
24         nums = re.findall(r'\d+', count_val)
25         return int(nums[0]) if nums else np.nan
26     return count_val
27
28 def calculate_group_timepoint(group_df, coeffs, sigma, p, q,
29                               c_thresh, min_week):
30     if group_df.empty:
31         return np.nan
32
33     z_score = norm.ppf(1 - p)
34     beta_week = coeffs.get('gw', 0)
```

```

34     if beta_week <= 0:
35         return float('inf')
36
37     non_week_vars = [k for k in coeffs.keys() if k not in ['gw
', 'Intercept']]
38
39     X_non_week = sm.add_constant(group_df[non_week_vars],
has_constant='add')
40     # 保证系数顺序与矩阵列顺序严格一致
41     coeffs_array = np.array([coeffs.get(col) for col in
X_non_week.columns])
42
43     # 向量化计算
44     non_week_pred = X_non_week.dot(coeffs_array)
45     numerator = (c_thresh - z_score * sigma) - non_week_pred
46     individual_weeks = (numerator / beta_week).clip(lower=
min_week)
47
48     # 计算分位数作为该组的推荐孕周
49     T_j = np.quantile(individual_weeks, q)
50     return T_j
51
52 def objective_func(params, df, coeffs, sigma, p, q, c_thresh,
min_week):
53     """
54     差分进化算法的目标函数：计算加权平均推荐孕周
55     """
56     b1, b2, b3 = params
57     # 约束条件
58     if not (20 <= b1 < b2 < b3 <= 50):
59         return float('inf')
60
61     df['group'] = pd.cut(df['bmi'], bins=[20, b1, b2, b3, 50],
labels=['G1', 'G2', 'G3', 'G4'], right=True, include_lowest
=True)

```

```

62     groups = df.groupby('group', observed=True)
63
64     # 如果分组数少于4, 说明该分割点无效
65     if len(groups) < 4:
66         return float('inf')
67
68     total_weighted_weeks = 0
69     for _, group_df in groups:
70         T_j = calculate_group_timepoint(group_df, coeffs,
sigma, p, q, c_thresh, min_week)
71         total_weighted_weeks += len(group_df) * T_j
72
73     return total_weighted_weeks / len(df)
74
75
76 # 主逻辑区
77 try:
78     data_df = pd.read_excel(FILE_PATH, sheet_name=SHEET_NAME)
79
80     data_df['检测孕周'] = data_df['检测孕周'].apply(parse_gw)
81     data_df['检测抽血次数'] = data_df['检测抽血次数'].apply(
get_blood_count)
82
83     data_df.rename(columns={
84         'Y染色体浓度': 'y_conc', '孕妇BMI': 'bmi', '检测孕周':
'gw',
85         '体重': 'weight', '身高': 'height', '年龄': 'age',
86         '检测抽血次数': 'blood_count'
87     }, inplace=True)
88
89     agg_rules = {
90         'bmi': 'mean', 'y_conc': 'mean', 'weight': 'mean',
91         'height': 'mean', 'age': 'mean', 'gw': 'first'
92     }
93     grouped_data = data_df.groupby(['孕妇代码', 'blood_count']

```

```

    ]).agg(agg_rules).reset_index()
94
95
96 # 模型求解
97 if not model_data.empty:
98     print("\n# 开始运行全局优化...")
99
100 # 定义搜索边界
101 bounds = [(20, 50), (20, 50), (20, 50)]
102
103 # 将参数打包成args元组传递给优化器
104 optimizer_args = (
105     model_data,
106     REG_RESULTS['coeffs'],
107     REG_RESULTS['sigma'],
108     MODEL_PARAMS['p_confidence'],
109     MODEL_PARAMS['q_proportion'],
110     MODEL_PARAMS['c_threshold'],
111     MODEL_PARAMS['min_week']
112 )
113
114 result = differential_evolution(
115     func=objective_func,
116     bounds=bounds,
117     args=optimizer_args,
118     seed=42
119 )

```

Question4.py

```

1 # 尝试导入 imblearn 相关库
2 try:
3     from imblearn.over_sampling import RandomOverSampler
4     from imblearn.pipeline import Pipeline as ImbPipeline
5     IMBALANCED_LEARN_AVAILABLE = True
6 except ImportError:

```

```

7     IMBALANCED_LEARN_AVAILABLE = False
8
9
10    # 模型训练配置
11    "test_size": 0.2,
12    "random_state": 42,
13    "cv_splits": 3, # 交叉验证折数
14    "svm_param_grid": {
15        'svm__C': [0.1, 1, 10, 100, 1000],
16        'svm__gamma': ['scale', 'auto', 0.01, 0.1, 1],
17        'svm__kernel': ['rbf', 'linear']
18    },
19    "scoring_metric": "f1_macro"
20 }
21
22 # 环境设定
23 warnings.filterwarnings('ignore')
24 plt.rcParams['font.sans-serif'] = ['SimHei']
25 plt.rcParams['axes.unicode_minus'] = False
26 sns.set(style="whitegrid", font='SimHei')
27
28
29 # 辅助函数区
30 def parse_gw(week_str):
31     if isinstance(week_str, str):
32         match = re.match(r'(\d+)w(?:\+(\d+))?', week_str)
33         if match:
34             weeks, days = int(match.group(1)), int(match.group
35 (2) or 0)
36             return weeks + days / 7
37         return np.nan
38
39 def calculate_diagnostic_metrics(y_true, y_pred, labels):
40     results = []
41     for cls in labels:

```

```

41         if cls == 'Normal': continue
42
43         y_true_binary = (y_true == cls)
44         y_pred_binary = (y_pred == cls)
45
46         tn, fp, fn, tp = confusion_matrix(y_true_binary,
47                                           y_pred_binary, labels=[0, 1]).ravel()
48
49         sensitivity = tp / (tp + fn) if (tp + fn) > 0 else 0
50         specificity = tn / (tn + fp) if (tn + fp) > 0 else 0
51         ppv = tp / (tp + fp) if (tp + fp) > 0 else 0
52
53         results.append({
54             '异常类型': cls, '真阳性(TP)': tp, '真阴性(TN)':
55             tn,
56             '假阳性(FP)': fp, '假阴性(FN)': fn, '敏感性':
57             sensitivity,
58             '特异性': specificity, '阳性预测值(PPV)': ppv
59         })
60     return pd.DataFrame(results)
61
62 def save_results_to_excel(writer, results_df, report_df, cm_df
63 , diag_df, params):
64     """将所有分析结果保存到一个Excel文件的不同工作表中"""
65     results_df.to_excel(writer, sheet_name='预测结果对比',
66 index=False)
67     report_df.to_excel(writer, sheet_name='各类别详细指标')
68     cm_df.to_excel(writer, sheet_name='混淆矩阵')
69     diag_df.to_excel(writer, sheet_name='医学诊断指标', index=
70 False)
71     pd.Series(params).to_excel(writer, sheet_name='模型最优参
72 数')
73     print(f"分析结果已写入Excel文件: {writer.path}")
74
75 # 主逻辑区

```

```

69 def main():
70     """执行完整的女胎NIPT异常判定分析流程"""
71     print(f"分析开始时间: {datetime.now().strftime('%Y-%m-%d %
72         H:%M:%S')}}")
73
74     # 准备工作: 建立结果目录
75     results_dir = CONFIG['results_dir']
76     results_dir.mkdir(parents=True, exist_ok=True)
77     (results_dir / "图表").mkdir(exist_ok=True)
78
79     # 数据载入与预处理
80     try:
81         data_df = pd.read_excel(CONFIG['data_file'])
82         print(f"成功载入数据: {CONFIG['data_file']}, 原始形状:
83             {data_df.shape}")
84     except FileNotFoundError:
85         print(f"错误: 找不到数据文件 '{CONFIG['data_file']}'")
86         return
87
88     data_df[CONFIG['target_column']].fillna('Normal', inplace=
89         True)
90     data_df['检测孕周_数值'] = data_df['检测孕周'].apply(
91         parse_gw)
92
93     model_data = data_df[data_df[CONFIG['target_column']].isin
94         (CONFIG['main_classes'])].copy()
95     model_data[CONFIG['feature_columns']] = model_data[CONFIG[
96         'feature_columns']].apply(pd.to_numeric, errors='coerce')
97     model_data.dropna(subset=CONFIG['feature_columns'],
98         inplace=True)
99     print(f"预处理完成, 用于建模的样本数: {len(model_data)}")
100
101     print("正在进行探索性数据分析 (EDA)...")
102     plt.figure(figsize=(10, 6))
103     sns.countplot(x=CONFIG['target_column'], data=model_data,

```



```

order=CONFIG['main_classes'])
97     plt.title('女胎染色体异常类型分布')
98     plt.tight_layout()
99     plt.savefig(results_dir / "图表" / "01_目标变量分布图.png"
, dpi=300)

100
101     # 模型训练与超参数调优
102     X = model_data[CONFIG['feature_columns']]
103     y = model_data[CONFIG['target_column']]
104
105     X_train, X_test, y_train, y_test = train_test_split(
106         X, y, test_size=CONFIG['test_size'], random_state=
CONFIG['random_state'], stratify=y
107     )
108
109     if IMBALANCED_LEARN_AVAILABLE:
110         print("检测到 imbalanced-learn, 使用 RandomOverSampler
处理数据不平衡。")
111         pipeline = ImbPipeline([
112             ('scaler', StandardScaler()),
113             ('sampler', RandomOverSampler(random_state=CONFIG[
'random_state'])),
114             ('svm', SVC(random_state=CONFIG['random_state'],
probability=True))
115         ])
116     else:
117         print("未检测到 imbalanced-learn, 使用 class_weight='
balanced' 处理。")
118         pipeline = Pipeline([
119             ('scaler', StandardScaler()),
120             ('svm', SVC(class_weight='balanced', random_state=
CONFIG['random_state'], probability=True))
121         ])
122
123     cv_strategy = StratifiedKFold(n_splits=CONFIG['cv_splits']

```

```

], shuffle=True, random_state=CONFIG['random_state'])
124     gscv = GridSearchCV(
125         pipeline, CONFIG['svm_param_grid'], cv=cv_strategy,
126         scoring=CONFIG['scoring_metric'], n_jobs=-1, verbose=1
127     )
128
129     print("开始进行网格搜索以寻找最优超参数...")
130     gscv.fit(X_train, y_train)
131     print(f"网格搜索完成。最优参数: {gscv.best_params_}")
132     print(f"交叉验证中最佳 {CONFIG['scoring_metric']} 分数: {
gscv.best_score_:.4f}")
133
134     # 模型评估与结果保存
135     final_model = gscv.best_estimator_
136     y_pred = final_model.predict(X_test)
137     y_pred_proba = final_model.predict_proba(X_test)
138
139     print("\n# 模型在测试集上的性能评估:")
140     report_dict = classification_report(y_test, y_pred,
output_dict=True, labels=CONFIG['main_classes'])
141     report_df = pd.DataFrame(report_dict).transpose()
142     print(report_df)
143
144     balanced_acc = balanced_accuracy_score(y_test, y_pred)
145     print(f"\n平衡准确率 (Balanced Accuracy): {balanced_acc:.4
f}")
146
147     # 建立结果表
148     results_df = X_test.copy()
149     results_df['真实标签'] = y_test
150     results_df['预测标签'] = y_pred
151     for i, class_name in enumerate(final_model.classes_):
152         results_df[f'{class_name}_预测概率'] = y_pred_proba[:,
i]
153

```

```

154     # 混淆矩阵
155     cm = confusion_matrix(y_test, y_pred, labels=CONFIG['
main_classes'])
156     cm_df = pd.DataFrame(cm, index=CONFIG['main_classes'],
columns=CONFIG['main_classes'])
157
158     # 诊断指标
159     diag_df = calculate_diagnostic_metrics(y_test, y_pred,
CONFIG['main_classes'])
160     print("\n# 医学诊断关键指标:")
161     print(diag_df.to_string(index=False))
162
163     # 保存结果
164     excel_path = results_dir / "NIPT女胎异常判定_完整分析报告.
xlsx"
165     with pd.ExcelWriter(excel_path, engine='openpyxl') as
writer:
166         save_results_to_excel(writer, results_df, report_df,
cm_df, diag_df, gscv.best_params_)
167
168     print(f"\n分析完成时间: {datetime.now().strftime('%Y-%m-%d
%H:%M:%S')}")
169
170 if __name__ == "__main__":
171     main()

```