

黄土高原各气候区多植被类型衰退现状与预测分析

摘要

黄土高原作为生态脆弱且地处关键过渡带的区域，在全球气候变化与人类活动双重胁迫下，植被退化问题日益严峻，严重威胁区域生态服务功能及可持续发展。然而，现有大尺度植被健康动态监测手段尚显不足，难以满足精准评估与预警的需求。为此，本研究针对黄土高原三种气候区与四种植被类型，旨在构建一套基于遥感大数据和支持向量机的精细化、分区化植被衰退评价与预测体系。

研究首先利用 2001-2015 年时序 NDVI 数据，通过 MK 检验与 Sen's slope 分析其变化趋势以界定衰退标签，并结合 IDW 插值和三次卷积重采样处理关键影响因子数据至 500 米分辨率。随后，以处理后的数据进行训练和测试，采用序列最小最优化（SMO）算法求解 SVM，系统评估了四种核函数捕捉非线性特征的能力，并通过严谨的超参数搜索与交叉验证，为 12 个分区（3 气候区×4 植被类型）分别构建了最优预测模型。最终，利用模型对 2016-2019 年独立数据进行预测，以准确率和召回率为核心指标评价模型性能。

测试结果显示，该模型体系在预测森林生态系统及半干旱区草地的衰退状况时展现出高准确率与召回率，具有良好的预测能力和预警潜力。但模型性能呈现显著的空间与植被类型异质性：对于受人为活动干扰强烈的耕地系统，以及水分条件较优越的半湿润区非森林植被，模型在召回率方面仍有提升空间，限制了其在这些特定情境下全面识别衰退实例的能力。

综上所述，本研究成功建立了一套精细化、分区化的植被衰退评价体系。该体系有效结合遥感大数据与优化后的 SVM 模型，能够可靠评估黄土高原大部分区域的植被状况，并证实了分区建模对于提升预测精度的必要性。研究成果可为黄土高原生态系统稳定性监测、适应性管理及可持续发展策略的制定提供关键的科学依据与技术支撑。

关键词：植被衰退评价体系；SVM 模型；空间插值；生态系统稳定性；分区建模

目录

摘要.....	1
表格与插图清单.....	4
一、引言.....	5
(一) 研究背景和意义.....	5
1.研究的生态学背景.....	5
2.大数据模型在生态学研究中的重要性.....	6
二、问题阐述.....	7
(一) 问题一：如何区分植被类型构建完整植被衰退评价体系.....	7
(二) 问题二：该模型预测的准确度如何，用于构建植被衰退预警信号的前景评价.....	8
三、模型假设.....	9
四、符号说明.....	10
五、材料与方法.....	11
(一) 气象数据来源与处理.....	11
1.IDW 插值原理.....	11
2.插值过程与数据转换.....	12
(二) 多元遥感数据分辨率统一.....	13
1.三次卷积插值法原理.....	13
2.三次卷积插值权重计算.....	13
3.空间变换与插值计算.....	13
(三) 植被衰退界定指标.....	14
六、问题一解决：植被衰退评价体系.....	15
(一) 问题背景与模型选择.....	15
(二) 模型构建.....	16
1.线性支持向量机模型构建.....	16
2.核技巧与非线性 SVM.....	19
(三) 模型求解.....	20

1.对偶问题.....	20
2.SMO 算法.....	21
(四) 结果分析.....	22
七、问题二解决：植被衰退预警信号.....	23
(一) 回顾模型.....	23
(二) 预测过程.....	24
(三) 结果分析.....	24
(四) 结论与展望.....	25
八、模型的分析与检验.....	25
(一) 误差分析.....	25
1.精确率分析.....	25
2.召回率与特异性分析.....	26
(二) 模型性能分析.....	27
1.可视化分析.....	27
2.结论.....	28
九、模型的评价.....	29
(一) 模型优势.....	29
(二) 模型局限.....	29
参考文献.....	33
附录.....	33

表格与插图清单

表 1.模型中使用的主要符号及其说明

表 2.植被衰退界定指标

表 3.每种核函数的超参数设定范围及说明

图 1.不同植被类型 NDVI 变化趋势

图 2.黄土高原区域概况图

图 3.研究流程图

图 4.气象因子空间分布图

图 5.气温站点差值数据示意图

图 6.半湿润区域的人工林分类结果

图 7.总体预测结果展示

图 8.四种植被类型各气候区 SVM 模型性能雷达图

图 9.12 个区域衰退与非衰退面积柱状图

一、引言

（一）研究背景和意义

1.研究的生态学背景

近年来，随着经济水平的迅速提升，全球气候变暖进程加快，极端气候事件频发。黄土高原位于中国北方干旱半干旱区，是我国典型的生态脆弱和气候敏感区，因其脆弱的自然条件和重要的地理位置，成为我国水土保持工程和退耕还林还草工程实施的重点区域。近 40 年来，黄土高原地区年均温度增加趋势明显，极端高温事件和复合干热胁迫严重影响了区域自然环境^[1]，气候变化呈现暖干化趋势^[2]。植被是陆地生态系统重要的组成部分，也是气候变化中最为敏感的部分，气候因素能够解释 58.2%的黄土高原植被变化现象^[3]。而人工栽植速生树种林分结构单一、后期养护不当^[4]，过度耕作和过度放牧等人类活动也是影响植被变化的重要因素之一。在以气候主导的多因子综合作用下，黄土高原植被退化严重，但受制于区域面积过大、地理数据难以获取、相关研究起步较晚等问题，目前仍缺乏能够准确识别和预测黄土高原植被退化区域的技术手段，NDVI 及其变化趋势做为评价不同植被类型衰退情况的关键指标，如何基于该指标全面构建植被衰退评价标签成为本问题的关键。




图 1 不同植被类型 NDVI 变化趋势

不同植被类型对温度、降水等气候因子的响应存在很大差异，在植被退化的研究中，应考虑划分植被类型和气候因子的空间差异，进而定量分析植被覆盖的

动态变化机制^[5]；且降雨是限制黄土高原植被生长的关键因子^[6]。黄土高原支离破碎的地形地貌导致自然条件呈显著空间异质性，年降水量自东南至西北递减^[7]；地区人类活动以农业生产和水土保持工程为主，形成了复杂的地带性气候和多样的植被类型。因此，本研究选取干旱、半干旱、半湿润 3 个气候区，草地、耕地、人工林、天然林 4 种植被类型（如图 2），针对不同气候区各植被类型的衰退，通过遥感数据处理与机器学习方法，分别构建 12 个分区内主要自然因子指征植被衰退的精确模型，以提供一种识别预测植被衰退区域的科学方法，实现对黄土高原地区植被变化的系统监测，为大尺度区域生态环境治理的全局规划奠定理论基础。




图 2 黄土高原区域概况图

2.大数据模型在生态学研究中的重要性

生态学研究具有数据量大、特征数据多、数据间相互作用关系复杂的特点。在生态要素间关系的研究中，传统的生态学研究通常采用主成分分析法(PCA)、回归分析和聚类分析等方法来解析生态要素间的关系，但存在忽略非线性关系、主成分解释性弱、对野外复杂数据适应性较差等缺点^[8]，难以进行准确分析。而对于较大的生态学数据集，模型训练拥有快速处理、模型稳定、可重复性强、物理机理依赖性低、侧重于算法的自主学习和判断等优势^[9]；相比传统方法基于典型现象的一般规律推导，机器学习提供了强大而高效的算法来处理非线性、高维

的生态数据，通常能取得更高的精度，也被越来越多地应用到目前的生态学领域中^[10]。

针对本研究的具体问题，我们选取“空间信息技术（3S）+支持向量机模型（SVM）”的技术手段有其独特优势。在对植被衰退识别的研究中，生态学学者通常选择实地调查获得的小班数据及枯梢率数据作为林地衰退指标，土壤微生物等数据作为草地衰退指标等，存在植被衰退指标不固定、数据获取主观性强、大尺度区域数据获取难等问题，往往影响了衰退识别的准确度。而随着卫星遥感技术逐渐发展，大面积和具有高时效性的遥感数据的获取难度大大降低，使得生态学研究空间中空间信息技术（3S）的应用逐渐与机器学习模型相结合^[11]。

支持向量机（SVM）是一种强大的监督学习模型，最初为解决二分类问题而设计^[12]。其核心思想是在特征空间中寻找一个最优超平面，以最大化不同类别样本之间的间隔。尤为关键的是，SVM 通过引入核技巧，能够有效处理非线性问题。通过选择合适的核函数，SVM 可以将原始数据隐式地映射到更高维甚至无限维的特征空间，在新的空间中寻求分离超平面，从而能够捕捉和模拟原始数据中复杂的非线性关系。

鉴于 SVM 在处理高维数据、解决非线性分类与回归问题方面的强大能力，以及其在模式识别领域的广泛成功应用，本研究采用支持向量机对空间信息技术处理的多元遥感数据进行计算，即将 NDVI（归一化植被指数）作为标签数据，将 TEM（年平均气温）、SPEI（标准化降水蒸发指数）、CO₂（二氧化碳平均浓度）、RH（相对湿度）、SM（土壤水分）、SSR（净太阳辐射）作为特征数据进行分类分析，并基于多年动态遥感数据实现不同分区主导自然因子与植被衰退函数关系模型的构建与检验，以搭建黄土高原区植被衰退识别与预测多元评价体系，为利用数学工具解决大尺度生态学问题提供科学的方案参考。

二、问题阐述

（一）问题一：如何分区分植被类型构建完整植被衰退评价体系

黄土高原地处干旱-半干旱-半湿润区过渡处，降水季节、年际变化较大，地处高原-平原、交界处，近年来随着目前对于衰退的界定不清，不同植被类型衰退机理不同。

黄土高原位于中国中部，是东部湿润区与西部干旱区的过渡地带，同时处于中国地势第二阶梯向第三阶梯的过渡区域。其独特的地理位置决定了该区域生态环境的**特殊性和敏感性**。受气候、水文、地形及土壤等自然因素影响，黄土高原生态系统具有较强的脆弱性，表现为水土流失严重、土地退化显著、植被覆盖率较低等特征。此外，长期以来的人类活动，如过度开垦、放牧及资源开发，进一步加剧了该区域**生态系统的退化风险**。

然而近年来，对于黄土高原植被退化的调查方法多采取样地调查所得的森林健康度等小班数据或仅从枯梢率定义植被衰退。然而传统样地调查在样地选择、指标权重、健康度等级划分具有**主观判断**，容易导致**人为误差**；所需成本高，时间、人力资源消耗大，且多为**静态采样**，无法满足大尺度生态系统健康动态监测的需求；单纯依赖枯梢率作为植被衰退的判定指标存在显著局限性。其仅反映植被外在形态的局部特征，易受季节性变化、自然更新及人为干扰等多因素影响，难以全面揭示植被健康状况与生态系统功能变化。目前对于衰退的界定不清，不同植被类型衰退机理不同，因此，如何**科学简洁结合多指标区分植被类型，构建植被衰退综合评价体系**，提升评价的客观性和适用性，成为本课题拟解决的关键问题。

（二）问题二：该模型预测的准确度如何，用于构建植被衰退预警信号的前景评价

近年来，在全球气候变化和人类干扰的双重影响下，黄土高原地区的植被退化问题日益突出。降水的高度季节性分布及极端天气事件的增多，使得植被生长受到较大限制；土壤侵蚀和水分流失导致植被根系难以稳定生长，生态系统自我修复能力下降。植被退化不仅加剧了区域水土流失问题，还影响了土壤肥力、碳循环及生态系统服务功能，对区域可持续发展构成严峻挑战。因此，准确预测植被衰退关键区域，提前预防植被衰退，对于该区域的生态恢复与可持续发展具有重要意义。因此，本研究针对问题一所建立的植被衰退评价体系，验证其预测的准确度，为**植被衰退预警信号**建立提供合理依据。

基于问题（一）和问题（二），构建具体思维流程如图3所示。




图3 研究流程图

三、模型假设

为了简化问题，聚焦核心驱动因素分析，并使模型在现有数据条件下可行，本研究做出以下主要假设：

假设1（NDVI 代表性）：假设归一化植被指数（NDVI）及其变化趋势相结合是衡量黄土高原主要植被类型（天然林、人工林、耕地、草地）健康状况和衰退程度的有效且充分的代表性指标。即 NDVI 及其变化能主要反映植被的衰退与恢复动态。

假设2（主要驱动因素）：假设选取的六个环境因子，即年平均气温(TEM)、标准化降水蒸发指数(SPEI)、二氧化碳平均浓度(CO₂)、相对湿度(RH)、土壤水分(SM)和净太阳辐射(SSR)，是影响研究区域内各植被类型 NDVI 变化（进而反映衰退状况）的最主要的自然驱动因素。其他未纳入模型的自然因素（如详细土壤养分、地形微地貌、病虫害等）或其对植被衰退的影响及因子间交互作用相对次要，或其影响与已部分所选因子具有较强耦合性。

假设3（时空尺度适宜性）：假设用于建模的遥感数据在其时间分辨率（生长季逐年数据）和空间分辨率上，能够捕捉到影响植被衰退的关键过程和格局。

即当前时空尺度下的数据足以反映研究问题所需的环境胁迫与植被响应关系，忽略了更高频率的环境季节性波动或更细微空间异质性的影响。

四、符号说明

表 1 模型中使用的主要符号及其说明

符号	说明	单位
$\mathbf{X}$	$\mathbf{X} = [x_1, x_2, x_3, x_4, x_5, x_6]$	无
x_1	TEM（年平均气温）	°C
x_2	SPEI（标准化降水蒸发指数）	无
x_3	CO ₂ （二氧化碳平均浓度）	ppm
x_4	RH（相对湿度）	%
x_5	SM（土壤水分）	M ³ /m ³ or %
x_6	SSR（净太阳辐射）	W/m ² or MJ • m ⁻² • day ⁻¹
y	NDVI（归一化植被指数）-模型标签/目标变量	无
TP	真正正类样本数（True Positives）	无
FP	假正类样本数（False Positives）	无
TN	真正负类样本数（True Negatives）	无
FN	假负类样本数（False Negatives）	无
Precision _{positive}	正类精确率	无
Precision _{negative}	负类精确率	无
Recall _{positive}	正类召回率	无
Recall _{negative}	负类召回率	无

五、材料与方法

（一）气象数据来源与处理

本研究所采用的气象数据（SSR、RH、CO₂、SPEI）来自国家气象信息中心 <http://data.cma.cn/>，NDVI 数据来源于地球资源数据云 <http://www.gis5g.com/home>，TEM 数据选取了研究区内的地面气象观测站点的年均气温数据，各气象站点的经纬度及对应的年均气温作为插值所需的基础数据。SM 数据利用 ERA5 再分析数据集的土壤湿度填补了 ESA-CCI 土壤湿度产品的缺失数据。随后，采用随机森林算法，辅以国际土壤湿度网络的实地观测和其他光学遥感数据集，将粗分辨率的土壤湿度数据降尺度到 500 米分辨率。干旱指数数据（AI）来源于欧盟委员会联合研究中心，按 AI 值将三北地区划分为极度干旱区、干旱区、半干旱区、半湿润区四个气候区，数据获取地址为 <https://wad.jrc.ec.europa.eu/patternsaridity>。为了确保数据的准确性和可用性，首先对原始数据进行了缺测值剔除与异常值检测，保留完整且质量较高的站点数据用于后续分析，各数据可视化后空间分布如图 4 所示。针对气象站点数据，我们进一步进行空间差值处理，具体步骤如下：




图 4 气象因子空间分布图

1.IDW 插值原理

为了获取研究区的空间连续性气温分布数据，采用了反距离权重（Inverse Distance Weighting, IDW）插值方法对站点气温数据进行空间插值^[13]。IDW 插值

法是一种基于空间自相关原理的确定性插值方法，其基本假设是空间上相邻的样本具有较大的相似性，距离插值点越近的观测值对该点的影响越大。具体计算公式为：

$$Z(x_0) = \frac{\sum_{i=1}^n w_i Z(x_i)}{\sum_{i=1}^n w_i} \quad \text{公式 (1)}$$

其中， $Z(x_0)$ 为待插值点的数值， $Z(x_i)$ 为第 i 个已知点的观测值， w_i 为第 i 个已知点的权重，权重的计算与距离成反比，一般采用如下公式：

$$w_i = \frac{1}{d_i^p} \quad \text{公式 (2)}$$

其中， d_i 为插值点与第 i 个已知点之间的距离， p 为幂指数，通常取值为 2。

2. 插值过程与数据转换

在具体操作中，利用 ArcGIS 软件的 Spatial Analyst 工具模块对站点年均气温数据进行 IDW 插值处理。设置搜索半径、幂指数等插值参数，以确保插值结果的平滑性和合理性。插值完成后，得到研究区连续分布的栅格气温数据，并将结果导出为 GeoTIFF (*.tif) 格式，用于后续空间分析和可视化研究，具体站点空间位置如下图所示：




图 5 气温站点差值数据示意图

（二）多元遥感数据分辨率统一

在本遥感数据分析中，已完成对于不同数据及的收集整理，然而不同数据源的栅格影像具有不同的空间分辨率。为实现多源数据的融合分析，对各影像进行空间重采样以统一分辨率。本研究采用三次卷积插值法（**Cubic Convolution Interpolation, CCI**），将 NDVI、TEM、SSR、SM、RH、CO₂、SPEI 数据统一至 500m 分辨率，具体实现方法如下：

1.三次卷积插值法原理

三次卷积插值是一种基于 16 个像元（4×4）的加权平均插值方法，其插值由目标像元周围的 16 个原始像元通过三次卷积函数计算得到^[14]。其数学表达式如下：

$$I'(x', y') = \sum_{i=1}^2 \sum_{j=1}^2 w(i, j) I(x+i, y+j) \quad \text{公式（3）}$$

其中：

$I(x, y)$ 为原始影响的像素值；

$w(i, j)$ 为三次卷积插值权重，由三次样条函数计算；

(x', y') 为目标像元坐标， (x, y) 为原始影响中最接近的整数像素坐标。

2.三次卷积插值权重计算

权重由以下三次卷积核函数确定：

$$w(t) = \begin{cases} (a+2)|t|^3 - (a+3)|t|^2 + 1 & 0 \leq |t| < 1 \\ a|t|^3 - 5a|t|^2 + 8a|t| - 4a & 1 \leq |t| < 2 \\ 0 & |t| \geq 2 \end{cases} \quad \text{公式（4）}$$

其中， $t = x' - x$ 为目标点与最近整数像素点的距离偏差，默认参数 $a = -0.5$ 可调整已优化平滑度。

3.空间变换与插值计算

①坐标变换

假设原始数据分辨率为 R_{old} ，目标分辨率为 R_{new} ，则目标栅格坐标 (x', y') 与原始栅格坐标 (x, y) 之间的关系为：

$$x' = \frac{x \cdot R_{old}}{R_{new}} \quad y' = \frac{y \cdot R_{old}}{R_{new}} \quad \text{公式（5）}$$

计算得到的新坐标通常为浮点数，需要向下取整找到最接近的整数像元 (x, y) 。

②插值计算步骤

选取最近的整数像素点 (x, y) ；

计算偏移量 $dx = x' - x$ 和 $dy = y' - y$ ；

计算权重 $w(dx)$ 和 $w(dy)$ ；

执行插值计算，先对 x 插值，再对 y 向插值：

$$I_x(y) = \sum w(i)I(x+i, y) \quad \text{公式 (6)}$$

$$I'(x', y') = \sum w(j)I_x(y+j) \quad \text{公式 (7)}$$

最终获得目标像素值 $I'(x', y')$ 。

本方法适用于连续变量（NDVI、温度、湿度、降水、辐射、CO₂ 浓度等）图像差值处理，平滑性较好，避免最近邻插值产生的锯齿效应且适用于高精度遥感分析，如 NDVI 变化趋势、气候变化研究等。经以上处理，可得统一分辨率的各因子数据集。

（三）植被衰退界定指标

基于以上数据集，进一步构建植被衰退评价指标，为 SVM 模型提供评价标签。本文运用 Sen's slope 方法估算多元时间序列黄土高原地区 NDVI 的变化趋势，同时应用 Mann-Kendall（MK）非参数秩次统计检验评估这些趋势的显著性^[15]。Sen's slope 是一种稳健的斜率估计方法，特别适用于高维数据中，通过逐步添加或删除变量，识别出数据中主要的趋势。MK 检验广泛用于检测时间序列数据中的单调趋势，它作为一种非参数工具，具有对数据分布无要求且能有效处理缺失值的优点。Sen's slope 方法和 MK 检验均通过高级统计软件实现，确保了趋势分析的准确性和可靠性。

在 Sen's slope 方法中，通过逐步迭代，选择对模型整体趋势最显著的变量进行添加或删除。这种方法有助于避免过拟合，并通过剔除影响较小的变量来简化模型复杂性。具体来说，

$$\text{Senslope} = \text{median} \left(\frac{Y_j - Y_i}{X_j - X_i} \right) \quad \text{公式 (8)}$$

其中， Y_j 和 Y_i 分别为时间序列在第 j 和第 i 个时间点的值， X_j 和 X_i 为相应的

时间点。

另一方面，MK 检验用于检测数据中的单调趋势，其检验统计量 S 的计算公式如下：

$$S = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(X_j - X_i) \tag{公式 (9)}$$

MK 检验的显著性通过计算标准正态变量 Z 来评估：

$$Z = \begin{cases} \frac{S-1}{\sqrt{\text{Var}(S)}} & S > 0 \\ 0 & S = 0 \\ \frac{S+1}{\sqrt{\text{Var}(S)}} & S < 0 \end{cases} \tag{公式 (10)}$$

其中， $\text{Var}(S)$ 为 S 的方差，通常在大样本情况下，若 $|Z|$ 大于 1.96，则认为趋势在 95% 的置信水平下显著。

针对不同植被类型，分别识别衰退栅格，具体标准如下：

表 2 植被衰退界定指标

衰退特征	NDVI	NDVI 变化趋势	p 值
草地	<0.2	<-0.005	<0.05
耕地	<0.3		
人工林	<0.4		
天然林	<0.6		

六、问题一解决：植被衰退评价体系

针对问题一所述的植被衰退数据获取困难、现有数据对植被衰退界定不全面，本研究通过收集大量遥感数据，经数据与处理后，运用归一化植被指数结合各遥感指标，综合构建植被衰退评价体系，具体方案如下：

（一）问题背景与模型选择

在黄土高原地区，气候、地形等自然因素加剧了植被退化问题，传统的样地调查方法存在主观性强和成本高的问题，无法满足大尺度动态监测需求。因此，本研究选用了支持向量机（SVM）作为植被衰退评价的模型。SVM 通过核技巧有效处理生态数据中的非线性关系，能够在高维特征空间中找到最优决策边界，从而适应复杂的植被退化模式。针对生态数据的高维性，SVM 能够避免过拟合

问题，并具有较强的鲁棒性和泛化能力。此外，通过为不同核函数设定合适的超参数范围，并进行交叉验证，本研究构建了 12 个优化后的 SVM 预测模型。这些模型能够为黄土高原地区不同生态区域的植被衰退预测提供科学依据，提升评价体系的客观性和适用性。

（二）模型构建

1. 线性支持向量机模型构建

线性支持向量机(Linear SVM)的核心目标是，在由多个生态相关指标构成的特征空间中，寻找一个最优的线性决策边界（超平面）^[16]。这个超平面定义为：

$$\omega^T \mathbf{X} + b = 0 \quad \text{公式 (11)}$$

其中：

$\mathbf{X}$ 是一个向量，代表某个具体地域单元（例如，一个遥感影像栅格）的生态指标测量值。 $\mathbf{X} = [x_1, x_2, x_3, x_4, x_5, x_6]$ 。

ω 是模型学习到的权重向量，它反映了不同生态指标对于区分土地状态（例如，退化与非退化）的重要性。

b 是偏置项，用于调整决策边界的位置。

这个超平面的目标是尽可能清晰地将 NDVI 指标反映的“退化”与“非退化”土地状态的样本点分离开。

考虑到现实生态数据往往存在噪声（如测量误差）或不同类别样本点在特征空间中并非完全线性可分，针对某些“退化”和“非退化”地块的生态指标组合可能很相似的情况，我们采用了软间隔 SVM 策略。该策略旨在找到一个间隔尽可能宽的决策边界，同时允许少数样本点出现在错误的一侧或间隔内部，但会对这种“错误”进行惩罚。

这种权衡通过引入非负的松弛变量 $\xi_i \geq 0$ 来实现，每个 ξ_i 对应一个训练样本 (x_i, y_i) 。软间隔 SVM 原始优化问题显示如下：

$$\begin{aligned} & \underset{\omega, b, \xi}{\text{minimize}} && \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^N \xi_i \\ & \text{subject to} && y_i (\omega^T x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \\ & && \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned} \quad \text{公式 (12)}$$

这里各项的生态学含义解释如下：

训练数据：

(x_i, y_i) 代表第 i 个训练地块（样本）的数据。 $x_i \in \mathbb{R}^d$ 是该地块的 d 维生态指标向量。 y_i 是其真实的土地状态标签，根据研究目标定义， $y_i = +1$ 代表非退化土地， $y_i = -1$ 代表退化土地。

目标函数：

$\frac{1}{2} \|\omega\|^2$ ：正则化项（L2 范数）。最小化权重向量 ω 的范数平方等价于最大化决策边界（超平面 $\omega^\top X + b = 0$ ）的几何间隔（ $\frac{2}{\|\omega\|}$ ）。在生态学背景下，一个更宽的间隔通常意味着模型对于输入生态指标的微小扰动更加鲁棒，不容易将特征相似但属于不同类别的地块混淆，这有助于提高模型在未见过的地块上预测的泛化能力。

$C \sum_{i=1}^N \xi_i$ ：经验风险项/误差惩罚项。 $\xi_i \geq 0$ 是松弛变量，用于度量第 i 个地块在多大程度上“允许”违反理想的间隔约束（即 $y_i(\omega^\top x_i + b) \geq 1$ ）。此项累加了所有训练地块的“违规”总量，并通过惩罚系数 C 进行加权。最小化该项意味着模型试图减少训练数据中的分类错误（即 $\xi_i > 1$ 的情况）或间隔内的模糊分类（即 $0 < \xi_i \leq 1$ 的情况）。

约束条件：

$y_i(\omega^\top x_i + b) \geq 1 - \xi_i$ ：此核心约束确保每个地块 i 根据其生态指标 x_i 和真实标签 y_i ，相对于决策边界被正确定位，同时允许通过非负的松弛变量 ξ_i 来容忍一定的错误或间隔内的点。如果一个点被正确分类且在间隔之外， $\xi_i = 0$ ；如果它在间隔内但仍被正确分类， $0 < \xi_i \leq 1$ ；如果它被错误分类， $\xi_i > 1$ 。

$\xi_i \geq 0$ ：确保松弛变量非负。

正则化参数：

$C > 1$ 是一个重要的超参数，称为惩罚系数。它控制着模型在结构风险最小化（追求大间隔，对应小 $\|\omega\|^2$ ）和经验风险最小化（减少训练错误，对应小 $\sum \xi_i$ ）之间的权衡。

较大的 C 值意味着对分类错误的惩罚更重，较小 C 值意味着对分类错误的容

忍度更高。

上述优化问题(1.)求解过程,等价于寻找 ω 和 b 以最小化如下的目标函数,该函数由两部分构成:所有样本的 Hinge 损失之和与 L2 正则化项^[17]:

$$\underset{\omega, b}{\text{minimize}} \quad C \sum_{i=1}^N \max(0, 1 - y_i(\omega^\top x_i + b)) + \frac{1}{2} \|\omega\|^2 \quad \text{公式 (13)}$$

这里, $\max(0, 1 - y_i(\omega^\top x_i + b))$ 被称为第 i 个样本的 Hinge 损失。我们选取 hinge 损失函数原因在于:

对于被错误分类的样本 (即 $y_i(\omega^\top x_i + b) < 0$), 其损失值大于 1, 且错得越远, 损失越大。

对于分类正确但处于间隔边界内部或边界上的样本 (即 $0 \leq y_i(\omega^\top x_i + b) < 1$), 其损失值在 $(0, 1]$ 区间内, 表示这些点虽然类别判断正确, 但模型对它们的区分度不够“自信” (离决策边界太近)。

对于分类正确且处于间隔边界之外的样本 (即 $y_i(\omega^\top x_i + b) \geq 1$), 其损失值为 0, 表明这些点被模型稳健地正确分类。

因此, 最小化 Hinge 损失旨在减少分类错误以及那些“不够确信”的正确分类样本数量。L2 正则化项 $\frac{1}{2} \|\omega\|^2$ 的作用与原始问题中相同, 即最大化间隔, 提升模型的泛化能力。

最终, 通过高效的优化算法求解上述问题 (或其等价的原始/对偶问题), 我们可以得到最优的权重向量 ω^* 和偏置 b^* 。这些参数共同定义了最优的决策超平面。

对于一个新的、状态未知的地块, 首先测量其对应的生态指标向量 $\mathbf{X}_{\text{new}}$ 。然后, 利用学习到的模型进行预测, 其决策函数为:

$$f(\mathbf{X}_{\text{new}}) = \text{sign}(\omega^{*\top} \mathbf{X}_{\text{new}} + b^*) \quad \text{公式 (14)}$$

预测规则如下:

如果 $f(\mathbf{X}_{\text{new}}) = +1$, 则模型预测该地块属于非退化类别。

如果 $f(\mathbf{X}_{\text{new}}) = -1$, 则模型预测该地块属于退化类别。

这个决策过程的几何意义是: 判断新的地块所对应的特征向量 $\mathbf{X}_{\text{new}}$ 落在由最优参数 ω^* 和 b^* 所确定的决策边界 ($\omega^{*\top} \mathbf{X} + b^* = 0$) 的哪一侧。落在正侧 (函数值

>0)即为预测非退化类,落在负侧(函数值 <0)即为预测退化类,以期正确预测是植被退情况。

2.核技巧与非线性 SVM

在前述章节中讨论了线性支持向量机(SVM)模型的构建,并解决了线性可分和线性不可分的情况。然而,在现实中,不同生态指标与土地退化状态之间的相互作用通常十分复杂,且呈现非线性关系,传统的线性支持向量机可能无法有效地划分“退化”与“非退化”地块。

核技巧的核心思想是通过一个非线性映射 $\Phi(\cdot)$,将原始的 d 维生态指标向量 $x \in \mathbb{R}^d$ 映射到一个更高维的特征空间 H ,在该空间中原本线性不可分的样本点可能变得线性可分。无需显式计算映射 $\Phi(x)$,只需要计算样本点在高维空间中的内积。具体地,内积可以通过一个在原始空间中定义的核函数 $K(x_i, x_j)$ 高效计算:

$$K(x_i, x_j) = \varphi(x_i)^\top \varphi(x_j) \quad \text{公式 (15)}$$

这使得我们能够在不进行复杂计算的情况下,通过核函数直接处理高维空间中的相似度,为后续对偶问题的求解提供了便利。

在本研究中,我们考虑了几种常用的核函数,以探索生态系统中的不同非线性关系:

①线性核 (Linear Kernel) :

$$K(x_i, x_j) = x_i^\top x_j \quad \text{公式 (16)}$$

线性核假设生态指标与土地退化之间存在线性关系,适合作为基准模型。

②径向基函数核 (RBF Kernel) :

$$K(x_i, x_j) = \exp\left(-\gamma \|x_i - x_j\|^2\right) \quad \text{公式 (17)}$$

RBF 核能够捕捉复杂的非线性关系,适合建模生态指标之间的高度非线性交互。

③多项式核 (Polynomial Kernel) :

$$K(x_i, x_j) = (\gamma x_i^\top x_j + r)^d \quad \text{公式 (18)}$$

多项式核能够显式建模生态指标之间的交互效应,尤其适用于描述生态系统中协同或拮抗的生态过程。

④Sigmoid 核 (Sigmoid Kernel) :

$$K(x_i, x_j) = \tanh(\gamma x_i^\top x_j + r) \quad \text{公式 (19)}$$

Sigmoid 核源自神经网络, 适用于模拟生态系统中存在的阈值效应或“激活”效应。

(三) 模型求解

1.对偶问题

在引入核函数后, 若直接在高维特征空间 H 中求解原始优化问题, 会因 $\Phi(x)$ 的未知性或极高维度而变得计算上不可行。因此, SVM 通常通过求解其拉格朗日对偶问题来获得模型参数。

求解对偶问题具有显著优势: 首先, 优化变量的数量仅依赖于训练地块 (样本) 数量 N , 与原始生态指标维度 d 或高维空间 H 的维度无关, 从而显著减少了计算复杂度。其次, 优化目标和约束中自然地出现了核函数 $K(x_i, x_j)$, 完全避免了对 $\Phi(x)$ 的显式计算。最后, 对偶问题的解通常是稀疏的, 模型的决策边界主要由少数关键的支持向量样本决定, 这进一步减少了模型的计算成本, 并提高了其有效性。

带有核函数的软间隔 SVM 的对偶优化问题形式如下:

$$\begin{aligned} \underset{\alpha}{\text{maximize}} \quad & W(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{subject to} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{aligned} \quad \text{公式 (20)}$$

其中 $\alpha = (\alpha_1, \dots, \alpha_N)^\top$ 是与每个训练地块 i 的约束相关联的拉格朗日乘子向量。

求解该对偶问题得到最优解 α^* 。那些具有非零乘子 $\alpha_i^* > 0$ 的训练地块样本 (x_i, y_i) 被称为支持向量。在生态学背景下, 这些支持向量代表了那些在生态指标特征上处于“退化”与“非退化”状态临界边缘的地块, 或者是那些难以被当前模型轻易区分, 可能在间隔内甚至被错分的地块。正是这些关键地块的生态特征信息, 决定了最终用于区分土地退化状态的决策边界。

最终，对于一个具有生态指标向量 x 的新地块，其状态（退化 $y = -1$ 或非退化 $y = +1$ ）的预测由以下决策函数给出：

$$f(x) = \text{sign} \left(\sum_{i \in SV} \alpha_i^* y_i K(x_i, x_j) + b^* \right) \quad \text{公式 (21)}$$

这个预测过程，实质上是计算新地块 x 与所有支持向量地块 x_i 之间在高维特征空间中的相似度（通过核函数 $K(x_i, x_j)$ 度量），并根据支持向量的类别 y_i 和其重要性权重 α_i^* 进行加权求和，最后加上偏置 b^* 来判断其归属。

2.SMO 算法

在本研究中，支持向量机(SVM)模型的求解基于其对偶优化问题(公式 20)，该优化问题本质上是一个二次规划(QP)问题。由于生态数据集通常包含大量的样本，直接求解大规模的 QP 问题会导致计算效率低下，因此，我们采用了序列最小最优化(SMO)算法。SMO 算法是一种高效的迭代优化方法，能够有效处理大规模训练数据，减少了计算开销，并提高了训练过程的效率^[18]。

SVM 模型的性能不仅依赖于求解算法的高效性，还在很大程度上取决于超参数的选择。为了平衡模型的复杂度和研究区域内植被退化模式的泛化能力，我们为四种核函数设定了一系列候选的超参数范围，具体在表 3 中显示。

在超参数搜索过程中，我们依次遍历每一种核函数及其超参数组合，训练 SVM 模型并对每个模型在测试集上的准确性进行评估。每个训练过程都使用了标准化后的训练数据 ($\mathbf{X}_{train \text{ scaled}}$)，并在测试集 ($\mathbf{X}_{test \text{ scaled}}$) 上进行预测，计算预测的准确率作为模型性能的评价指标。

在完成超参数搜索后，所有实验结果按照准确率降序排序，并选择每种核函数的最佳超参数组合。为了进一步验证模型的稳定性和泛化能力，我们对每个最优参数组合进行了交叉验证，并选择在交叉验证中表现最优的模型。这个模型便是最终的预测模型，并将在不同区域的生态数据上进行预测。

通过该过程，我们成功地为不同的生态区域和植被类型训练了 12 个不同的预测模型。每个模型均基于不同的超参数组合和核函数配置，针对特定的生态区域进行了优化。

表 3 每种核函数的超参数设定范围及说明

核函数类型	超参数	设定范围（候选值）
线性核（Linear）	C	$\{0.1, 1, 10\}$
径向基核（RBF）	C	$\{0.1, 1, 10\}$
	γ	$\{0.1, 0.4, 1\}$
多项式核（Polynomial）	C	$\{0.1, 1, 10\}$
	γ	$\{0.1, 0.4, 1\}$
	$d(\text{degree})$	$\{2, 3\}$
	$r(\text{coef}0)$	$\{0.0, 1.0\}$
Sigmoid 核	C	$\{0.1, 1, 10\}$
	γ	$\{0.1, 0.4, 1\}$
	$r(\text{coef}0)$	$\{0.0, 1.0\}$

惩罚参数 C ：控制模型对误分类的容忍度，影响分类边界的“软硬”程度（间隔大小）。

核参数 γ ：定义了单个训练样本影响范围的大小，控制样本间相似性的度量尺度（对 RBF、多项式、Sigmoid 核）。

多项式次数 d ：指定多项式核函数的阶数，影响模型捕捉数据非线性特征的能力。

系数 $r(\text{coef}0)$ ：核函数中的常数项，对多项式核和 Sigmoid 核的映射方式有影响。

综上所述，本研究通过系统的超参数搜索和优化，基于 SVM 模型成功构建了多个植被退化预测模型。这些模型的训练过程和预测结果为未来的生态环境管理和保护措施提供了科学依据，同时为植被退化的早期预警和恢复策略的制定提供了技术支持。

（四）结果分析

在本研究中，我们针对不同区域和植被类型的生态数据进行分类训练，使用支持向量机（SVM）模型对每个数据集进行建模，最终生成了 12 个预测模型。每个模型分别对应于不同的生态区域和植被类型。

由于训练数据具有较高的维度（六个特征维度），直接绘制高维分类超平面以展示模型的输出结果变得不可行。因此，为了便于可视化展示，我们从六个特征中随机选择了三个特征，并基于高维数据训练出的模型绘制三维超平面。这种方法允许我们直观地展示不同核函数在三维空间中的分类效果。为了具体说明模

型的分类能力，我们选取了“半湿润区域的人工林”作为展示对象，展示了四种核函数所绘制的分类超平面，如图 6 所示，并比较了它们在该区域数据上的分类性能。




图 6 半湿润区域的人工林分类结果

七、问题二解决：植被衰退预警信号

在问题一中，我们成功构建了基于支持向量机（SVM）的植被退化预测模型，并通过多种核函数对生态区域进行训练和优化。本部分将探讨如何利用这些训练好的 SVM 模型进行预测，并分析模型在不同生态区域和植被类型上的表现。

（一）回顾模型

如前所述，我们使用四种不同的核函数对不同区域和植被类型的数据进行了训练。在模型训练过程中，我们通过超参数搜索，调整了模型的各项参数，以优化模型性能并提高其预测精度。并且通过交叉验证等技术，我们找到了每种核函数的最佳参数组合，最终得到了 12 个经过优化的预测模型。

（二）预测过程

在完成模型训练和超参数优化后，我们开始运用训练得到的 SVM 模型进行预测。具体而言，对于一个新的待预测地块，首先提取其生态指标向量 $\mathbf{X}_{\text{new}}$ ，然后将其输入到训练好的 SVM 模型中进行预测。模型的预测结果由决策函数给出，形式如下：

$$f(\mathbf{X}_{\text{new}}) = \text{sign}(\omega^{*T} \mathbf{X}_{\text{new}} + b^*) \quad \text{公式 (22)}$$

根据模型的输出，如果 $f(\mathbf{X}_{\text{new}}) = +1$ ，则该地块被预测为非退化；如果 $f(\mathbf{X}_{\text{new}}) = -1$ ，则被预测为退化。通过这一预测过程，我们能够依据生态指标来判断不同地块的退化状态，为生态保护和土地管理提供决策依据。

（三）结果分析

为了便于理解和展示模型的预测能力，我们对不同核函数训练得到的 SVM 模型在多个生态区域和植被类型上的表现进行了可视化展示。由图可知，与现有植被衰退数据对比，由 SVM 模型预测的黄土高原 12 个区域植被衰退结果中总体正确率在 81.25%-96.62%之间，其中，对于耕地、人工林、天然林不同气候区的植被衰退预测精度均高于 90%，对于草地的衰退预测精度稍低。研究给出了不同类型区域土地的桑基图，具体准确率如图 7 所示：




图 7 总体预测结果展示

（四）结论与展望

从图中可以看出，本研究通过对多个生态区域和植被类型的训练和测试，成功构建了多个基于 SVM 的植被退化预测模型。每个模型都经过了精细的超参数调整，并基于不同的核函数优化。最终的模型不仅能够为土地退化监测提供科学依据，还能为后续的生态恢复与管理提供技术支持。

八、模型的分析与检验

（一）误差分析

在预测模型评估中，仅关注整体准确率往往不足以反映模型的真实性能，尤其是在处理类别不平衡数据时。在生态系统中，常常出现正负样本量不对等的情况，黄土高原不同植被类型各气候区均以非衰退为主，衰退栅格样本量较少。然而在预测过程中，准确识别衰退栅格并进行提前人为干预区域相较于预测出非衰退的数据更为重要。在本研究中大部分衰退数据和非衰退数据的比例为 10: 1，呈现数据集不对等的情况，因此进行误差分析是十分有必要的。

在此背景下，错误地将退化土地预测为未退化可能导致错失最佳干预时机，加速生态系统恶化；而错误地将未退化土地预测为退化则可能导致不必要的资源投入和管理干预。因此，必须采用能够区分不同类型预测错误的评估指标，对模型在正类和负类样本上的表现进行细致分析。本节重点引入并讨论精确率和召回率及其在生态学背景下的解读。

1. 精确率分析

精确率衡量的是模型预测为某一特定类别的样本中，真正属于该类别的比例，反映了模型预测结果的“准确性”或“可靠性”。

正类精确率：指在所有被模型预测为“未退化”（正类）的土地单元中，实际上确实是未退化的比例。其计算公式为：

$$\text{Precision}_{\text{positive}} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad \text{公式 (23)}$$

其中，TP 是正确预测为未退化的样本数，FP 是错误预测为未退化的样本数（实际为退化）。高正类精确率意味着当模型预测某地块未退化时，这个判断具有较高的可信度，有助于避免对健康土地进行不必要的监测或干预。

负类精确率：指在所有被模型预测为“退化”（负类）的土地单元中，实际上确实是退化的比例。其计算公式为：

$$\text{Precision}_{\text{negative}} = \frac{\text{TN}}{\text{TN} + \text{FN}} \quad \text{公式 (24)}$$

其中，TN 是正确预测为退化的样本数，FN 是错误预测为退化的样本数（实际为未退化）。在生态恢复和管理实践中，负类精确率至关重要。它直接关系到资源分配的有效性——高负类精确率确保了当我们根据模型预测结果投入资源进行退化土地恢复时，这些资源更有可能用在真正需要干预的地块上，提高了干预措施的针对性和效率。

综合评估正类和负类精确率，能够全面揭示模型在区分不同土地状态时的可靠程度。特别是在处理类别不平衡的生态数据时，关注负类精确率有助于我们理解模型在识别关键少数类（退化土地）时的实际效用。

2. 召回率与特异性分析

召回率（也称敏感性）衡量的是模型正确识别出所有实际属于某一特定类别的样本的能力。正类召回率：指在所有实际为“未退化”（正类）的土地单元中，被模型成功识别出来的比例。其计算公式为：

$$\text{Recall}_{\text{positive}} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad \text{公式 (25)}$$

其中，FN 是实际未退化但被错误预测为退化的样本数。高正类召回率意味着模型能够有效地找出大部分健康的土地，为划定保护区边界或评估生态系统整体健康状况，减少不必要管理资源的浪费提供参考价值。

负类召回率：通常在二分类问题中，对负类的“召回率”称为特异性。它指在所有实际为“退化”（负类）的土地单元中，被模型成功识别出来的比例。其计算公式为：

$$\text{Recall}_{\text{negative}} = \frac{\text{TN}}{\text{TN} + \text{FP}} \quad \text{公式 (26)}$$

其中，FP 是实际退化但被错误预测为未退化的样本数。在土地退化预测的生态学应用中，特异性（负类召回率）往往是极为关键的指标。衰退地块是生态系统退化治理中的优先干预单元。模型具有较高特异性，意味着其在识别非衰退区域时具有较强的判别能力，从而最大限度地减少对实际已衰退区域的漏判。漏判衰退区域不仅可能导致其生态功能持续衰退，还可能引发更广泛的生态风险，

引发蝴蝶效应，显著增加后期修复的生态成本与技术难度。因此，提升模型的特异性对于构建高效的生态预警体系、实现退化地块的精准识别与及时干预具有重要意义。

通过同时考察召回率（正类）和特异性（负类召回率），我们可以评估模型在“找全”各类土地状态方面的能力，尤其是在确保不遗漏关键的退化区域方面的表现。

（二）模型性能分析

1.可视化分析

为系统评估和比较本研究针对黄土高原不同气候区（干旱区、半干旱区、半湿润区）和不同植被类型（草地、耕地、人工林、天然林）所构建的 12 个支持向量机（SVM）植被衰退预测模型的性能，我们采用了雷达图进行多维度可视化展示。如图 8 所示，四张雷达图分别展示四种植被类型在各气候类型下的准确率与召回率。




图 8 四种植被类型各气候区 SVM 模型性能雷达图

每张雷达图以三个气候区（干旱、半干旱、半湿润）作为基本轴，并在这些轴上绘制了两个关键性能指标：总体准确率和召回率，每个顶点标注的数值即代表该植被类型在特定气候区训练得到的 SVM 模型的具体性能表现。这种可视化方式能够直观地揭示各模型在不同地理和植被背景下的优势与不足。

从图 8 中可以观察到，所有模型的总体准确率（粉色区域）普遍维持在较高水平，大部分数值超过 0.70，甚至在森林类型中接近或超过 0.80-0.90。这表明模型在整体上区分样本（包含衰退与非衰退像元）的能力较强。然而，召回率（蓝色区域）的表现则呈现出更大的变异性。在多数情况下，准确率的覆盖范围大于或等于召回率，这可能部分反映了数据集中非衰退样本占多数（数据不平衡）的

现实，模型对多数类的准确分类对总体准确率贡献较大。因此，仅凭高准确率不足以完全评价模型效果，召回率对于识别出真正衰退的区域尤为关键。

①不同植被类型的性能差异：对比四种类型的雷达图，

天然林与人工林：这两种森林类型的模型表现最为出色且均衡。在准确率和召回率上，各气候区均展现了较高的性能（多数指标 >0.70 ，部分接近 0.90 ）。这表明基于所选气候因子的 SVM 模型对于预测森林生态系统的衰退状况具有较好的稳定性和可靠性。

耕地：耕地模型的准确率尚可，但在召回率方面表现相对较弱，尤其是在半湿润区，召回率显著偏低（图中数值为 0.15 ）。这与我们之前的分析一致，即耕地系统受到强烈的人为管理活动（如灌溉、施肥、地膜铺设等）影响，单纯依赖气候因子难以完全捕捉其 NDVI 变化或“衰退”的真实驱动因素，导致模型识别真正衰退样本的能力受限。在之后的模型分析中，应全面考虑人为条件干扰导致的耕地衰退情况。

草地：草地模型的性能表现出显著的气候区依赖性。在半干旱区，模型展现了极高的召回率（ 0.84 ），说明在此环境下模型能有效识别出衰退的草地。然而，在半湿润区，召回率大幅下降至 0.41 ，而在干旱区的表现也较为一般（召回率 0.60 ）。这种巨大的差异可能反映了不同水分条件下草地对气候因子响应敏感性的变化，或是模型在不同区域捕捉主导驱动因素的能力有所不同。

②气候区对模型性能的影响：

从气候分区角度看，模型性能也存在差异。半湿润区的模型（尤其对草地和耕地）普遍显示出较低的召回率，这可能意味着在水分相对充足的条件下，植被动态对本研究选取的这组气候因子的依赖性降低，或者存在其他更强的驱动因素（如土壤养分、人类活动细节）未被模型充分考虑。半干旱区和干旱区的模型性能则各有特点，例如半干旱区草地召回率高，但耕地准确率相对最低。

2.结论

综合来看，雷达图的可视化分析结果清晰地展示了基于 SVM 的植被衰退预测模型在不同地理背景和植被类型下的性能特征。模型在森林生态系统以及半干旱区的草地展现了较好的预测能力和预警潜力。然而，对于受人为干扰显著的耕地，以及水分条件较好的半湿润区的非森林植被，模型的召回率有待提高。这提

示我们在实际应用中需要根据具体对象和区域选择性地信赖模型结果，并考虑在模型表现不佳的区域进一步优化模型，例如引入更多反映局地环境和人类活动的特征变量，或调整模型算法与参数。

九、模型的评价

（一）模型优势

本研究构建的植被衰退预测模型具有多方面的优势。首先，模型的核心优势在于**利用遥感大数据实现了大尺度植被动态监测**。基于 3S 技术，利用大范围、高时效性的遥感数据作为输入，克服了传统样地调查成本高、主观性强、时效性差的局限性，为黄土高原大范围生态系统检测提供了客观、动态的植被状况监测手段。

其次，模型通过**针对性分区建模提升预测精度**。研究针对黄土高原内部存在的 3 个显著气候梯度（干旱、半干旱、半湿润区）以及 4 种不同植被类型（草地、耕地、人工林、天然林）对环境因子响应的特异性，分别构建了 12 个独立的 SVM 预测模型。精细地考虑了区域气候异质性以及不同植被类型对环境因素响应的差异，显著提高了模型的地域适用性和预测精度。

第三，模型选用的**支持向量机算法及运用核技巧处理非线性关系**。生态系统中，环境因子与植被生长指标之间的相互作用往往呈现高度非线性特征。SVM 通过引入核函数，能够将数据映射到高维特征空间，从而有效捕捉和模拟这些复杂的非线性依赖关系，这相较于传统的线性模型更能贴合真实生态过程的复杂动态。

第四，SVM 模型具备**良好的高维数据处理能力**。模型能够有效处理包含多个环境因子的高维输入数据，从中学习复杂的潜在模式，有效避免了高维数据带来的求解问题。

最后，研究过程**注重模型的优化与泛化能力**。通过采用系统的超参数搜索方法并结合交叉验证技术来选择最优的模型参数组合及评估模型性能，旨在最大程度地提升模型在未见过数据上的泛化能力和预测稳定性。提升模型在新数据上的泛化能力和预测稳定性，降低过拟合风险。

（二）模型局限

尽管模型展现出诸多优势，但也存在一些固有的局限性和面临的挑战。首先，

模型面临的一个主要挑战是**数据不平衡问题**。研究区域内非退化（正类）样本数量远超退化（负类）样本，这种类别不平衡可能导致模型训练时偏向于多数类，从而影响其准确识别和预测衰退植被的能力，如图 9 所示。

其次，**耕地生态系统模型的解释受到人类活动的制约**。对于耕地植被类型，其生长状况受人为管理（如灌溉、施肥、耕作措施）的强烈影响。虽然模型可基于气候等因子预测 NDVI，但这些自然因子的相对重要性和解释力可能被显著削弱或干扰，难以清晰分离自然驱动与人为管理对植被状态的贡献。

第三，**将单一的 NDVI 及其变化作为植被“衰退”的唯一标签存在固有限制**。单一依赖 NDVI 及其变化趋势作为植被“衰退”的标签对于植被衰退评价不够全面。NDVI 主要反映覆盖度和生物量，存在明显的季节性波动，难以全面捕捉植被衰退的多维度特征，如物种多样性组成、群落结构简化、生理胁迫早期信号等。

最后，模型的**性能高度依赖于输入数据的质量**。模型的性能高度依赖于高质量的遥感数据和生态指标。如果输入数据中存在误差、噪声或缺失值，模型的准确性和可靠性将受到影响。在实际应用中，数据质量控制和缺失值处理需要特别重视，否则会影响模型的预测结果，特别是在大尺度区域内，数据采集过程中的误差可能被放大，进而影响模型的整体表现。




图 9 12 个区域衰退与非衰退面积柱状图

参考文献

- [1] 张更喜,王慧敏,栗晓玲,等.复合干热胁迫下黄土高原夏季植被脆弱性评估[J].农业工程学报,2024,40(6):339-346.
- [2] 胡娜娜,延军平,李双双,等.气候暖干化背景下黄土高原旱涝时空演变特征[J].干旱区研究,2013,30(04):705-711.
- [3] 汪士为,吴伟.气候因素与黄土高原植被的时间滞后关系分析[J].草业科学,2025,42(2):329-339.
- [4] 张韶立.(2020).“三北”防护林工程退化林分修复改造技术研究.山西林业,2020(1),20-21.
- [5] 耿庆玲,陈晓青,赫晓慧,等.中国不同植被类型归一化植被指数对气候变化和人类活动的响应[J].生态学报,2022,42(09):3557-3568.
- [6] 赵安周,刘宪锋,朱秀芳,潘耀忠,陈抒展.2000—2014年黄土高原植被覆盖时空变化特征及其归因.中国环境科学,2016,36(5):1568-1578.
- [7] 刘玉鹏,钞锦龙,路亚敏,等.1959-2018年黄土高原地区降水时空变化研究[J/OL].高原气象,1-10[2025-04-02].
- [8] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [9] 李慧杰,王兵,牛香,等.机器学习技术在生态学中的应用进展[J].生态学杂志,2023,42(11):2767-2775.
- [10] Thessen A. 2016. Adoption of machine learning techniques in ecology and earth science. One Ecosystem, 1: e8621.
- [11] 苏显辉,杨军.基于多源遥感数据的森林优势树种提取[J].林业勘查设计,2025,54(02):78-81.
- [12] 李航. 统计学习方法[M].第2版.北京:清华大学出版社,2019.
- [13] Liu Z N, Yu X Y, Jia L F, et al. The influence of distance weight on the inverse distance weighted method for ore-grade estimation[J]. Scientific Reports, 2021, 11(1): 2689.
- [14] Wang X, Hu S, Li M, et al. Corrupting convolution-based unlearnable datasets with pixel-based image transformations[J]. arXiv preprint arXiv:2311.18403, 2023.

- [15] Zhou J, Deitch M J, Grunwald S, et al. Do the Mann-Kendall test and Theil-Sen slope fail to inform trend significance and magnitude in hydrology?[J]. Hydrological Sciences Journal, 2023, 68(9): 1241-1249.
- [16] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20: 273-297.
- [17] Wang H, Shao Y, Zhou S, et al. Support Vector Machine Classifier via $L_{0/1}$ Soft-Margin Loss[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(10): 7253-7265.
- [18] Keerthi S S, Shevade S K, Bhattacharyya C, et al. Improvements to Platt's SMO algorithm for SVM classifier design[J]. Neural computation, 2001, 13(3): 637-649.

附录

预测模型代码（部分）

```
1. # 导入必要的库
2. import pandas as pd # 用于数据处理和分析
3. import numpy as np # 用于数值计算
4. import matplotlib.pyplot as plt # 用于数据可视化
5. from sklearn.model_selection import train_test_split # 用于数据集分割
6. from sklearn.svm import SVC # 支持向量机分类器
7. from sklearn.metrics import accuracy_score # 用于计算分类准确率
8. from sklearn.preprocessing import StandardScaler # 用于数据标准化
9. from itertools import product # 用于生成参数组合
10. import time # 用于计时
11. import warnings # 用于控制警告信息
12.
13. # 忽略可能出现的收敛警告
14. warnings.filterwarnings("ignore", category=UserWarning)
15.
16. # 尝试设置中文字体，以便图表正确显示中文
17. try:
18.     plt.rcParams['font.sans-serif'] = ['SimHei'] # 或使用 'Microsoft YaHei'
等
19.     plt.rcParams['axes.unicode_minus'] = False # 解决负号显示问题
20. except Exception as e:
21.     print(f"设置中文字体失败: {e}。图表中的中文可能无法正常显示。")
22.
23. print("--- 开始执行 SVC 超参数搜索与评估 ---")
24.
25. # --- 1. 数据加载与初步检查（训练数据） ---
26. try:
27.     # 训练数据文件路径（替换为您的实际路径）
28.     train_file_path = r"C:\Users\31105\Desktop\xlsx\人工干 1.xlsx"
29.     train_data = pd.read_excel(train_file_path, sheet_name='Sheet1') # 读
取训练数据
30.     print(f"\n[数据加载] 成功加载训练数据 '{train_file_path}'")
31.     print(f" 数据维度: {train_data.shape[0]} 行, {train_data.shape[1]} 列")
")
32. except FileNotFoundError:
33.     print(f"错误: '{train_file_path}' 文件未找到。请确保文件路径正确。")
34.     exit()
35. except Exception as e:
36.     print(f"读取训练数据 Excel 时发生意外错误: {e}")
37.     exit()
38.
```

```

39. # 检查训练数据是否有足够的列
40. if train_data.shape[1] < 6:
41.     print(f"错误: 训练数据 Excel 文件只有 {train_data.shape[1]} 列, 不
足以提取 5 个特征和 1 个标签。")
42.     exit()
43.
44. # 提取训练数据的特征和标签
45. y_train = train_data.iloc[:, 0] # 第一列作为标签 (NDVI)
46. X_train = train_data.iloc[:, 1:6] # 第 2-6 列作为特征
47. feature_names = list(X_train.columns) # 提取特征名称
48. label_name = train_data.columns[0] # 标签列名
49.
50. # 打印训练数据基本信息
51. print(f" 特征列: {feature_names}")
52. print(f" 标签列: {label_name}")
53. unique_labels = y_train.unique()
54. print(f" 标签类别: {unique_labels}")
55. print(f" 标签类别数量: {len(unique_labels)}")
56. print(f" 标签类别分布:\n{y_train.value_counts(normalize=True).round(4)}")
57.
58. # 检查标签类别是否足够用于分类
59. if len(unique_labels) < 2:
60.     print("警告: 训练数据标签列只有一个类别, 无法进行有效的分类训
练。")
61.     exit()
62.
63. # 检查训练数据是否有重复行
64. duplicate_rows = train_data.duplicated().sum()
65. if duplicate_rows > 0:
66.     print(f"\n[数据检查] 警告: 训练数据中发现 {duplicate_rows} 行完全
重复的数据。")
67. else:
68.     print("\n[数据检查] 训练数据未发现完全重复的数据行。")
69.
70. # --- 2. 数据标准化 ---
71. print("\n--- 数据标准化 ---")
72. scaler = StandardScaler()
73. X_train_scaled = scaler.fit_transform(X_train) # 在训练集上拟合并转换
74. print(" 数据标准化完成 (StandardScaler 在训练集上拟合)。")
75.
76. # --- 3. 定义超参数搜索范围 ---
77. print("\n--- 定义超参数搜索范围 ---")
78. kernels_to_search = ['linear', 'rbf', 'poly', 'sigmoid']
79. kernel_display_names = ['Linear', 'RBF', 'Polynomial', 'Sigmoid']

```

```

80.
81. # 定义超参数范围
82. C_range = np.logspace(-1, 1, num=3) # [0.1, 1, 10]
83. gamma_range_numeric = np.logspace(-1, 0, num=3) # [0.1, 0.4, 1]
84. gamma_range = list(gamma_range_numeric) + ['scale']
85. degree_range = np.arange(2, 4, 1) # [2, 3]
86. coef0_range = np.linspace(0.0, 1.0, num=2) # [0.0, 1.0]
87.
88. # 打印搜索范围信息
89. print(f" 核函数: {kernels_to_search}")
90. print(f" C 范围: {C_range.tolist()}")
91. print(f" Gamma 范围: {gamma_range}")
92. print(f" Degree 范围: {degree_range.tolist()}")
93. print(f" Coef0 范围: {coef0_range.tolist()}")
94.
95. # --- 4. 执行超参数搜索 ---
96. print("\n--- 开始循环训练和评估 (超参数搜索) ---")
97. all_results = []
98. start_time = time.time()
99. combination_count = 0
100. failed_combinations = 0
101.
102. for kernel in kernels_to_search:
103.     print(f"\n-- 测试核函数: {kernel.upper()} --")
104.     param_iter = None
105.     param_names = []
106.     if kernel == 'linear':
107.         param_iter = product([kernel], C_range)
108.         param_names = ['kernel', 'C']
109.     elif kernel == 'rbf':
110.         param_iter = product([kernel], C_range, gamma_range)
111.         param_names = ['kernel', 'C', 'gamma']
112.     elif kernel == 'poly':
113.         param_iter = product([kernel], C_range, gamma_range, degree_range,
coef0_range)
114.         param_names = ['kernel', 'C', 'gamma', 'degree', 'coef0']
115.     elif kernel == 'sigmoid':
116.         param_iter = product([kernel], C_range, gamma_range, coef0_range)
117.         param_names = ['kernel', 'C', 'gamma', 'coef0']
118.
119.     for params_tuple in param_iter:
120.         combination_count += 1
121.         params_dict = dict(zip(param_names, params_tuple))
122.         current_svc_params = {'probability': False, 'random_state': 42}

```

```

123.         current_svc_params.update(params_dict)
124.
125.         try:
126.             svc = SVC(**current_svc_params)
127.             svc.fit(X_train_scaled, y_train)
128.             y_pred = svc.predict(X_train_scaled) # 在训练集上预测以
评估性能
129.             accuracy = accuracy_score(y_train, y_pred)
130.
131.             result_entry = params_dict.copy()
132.             result_entry['accuracy'] = accuracy
133.             result_entry['full_params'] = current_svc_params
134.             all_results.append(result_entry)
135.         except Exception as e:
136.             failed_combinations += 1
137.             print(f" 训练/评估失败, 参数: {params_dict} - 错误: {e}")
138.
139.     end_time = time.time()
140.     total_time = end_time - start_time
141.     print(f"\n--- 参数搜索完成 ---")
142.     print(f"总共测试了 {combination_count - failed_combinations} 组有效参数
组合 (跳过 {failed_combinations} 组)。")
143.     print(f"总耗时: {total_time:.2f} 秒")
144.
145.     # --- 5. 查找最佳模型 ---
146.     print("\n--- 查找最佳参数组合 ---")
147.     best_results_per_kernel = {}
148.     if not all_results:
149.         print("错误: 没有成功的训练结果, 无法继续。")
150.         exit()
151.     else:
152.         results_df = pd.DataFrame(all_results)
153.         results_df_sorted = results_df.sort_values(by='accuracy', ascending=False)
154.         print("\n--- 最佳参数组合 (Top 5 Overall) ---")
155.         print(results_df_sorted.head(5))
156.
157.         for i, kernel in enumerate(kernels_to_search):
158.             kernel_name_display = kernel_display_names[i]
159.             kernel_results = results_df_sorted[results_df_sorted['kernel'] ==
kernel]
160.             if not kernel_results.empty:
161.                 best_for_kernel = kernel_results.iloc[0:1]
162.                 best_params_dict = best_for_kernel.iloc[0].to_dict()
163.                 print(f"\n最佳 {kernel_name_display} 核:")

```

```

164.         params_to_show = {k: (f'{v:.4g}' if isinstance(v, (float,
np.float_)) else v)
165.                             for k, v in best_params_dict.items()
166.                             if k not in ['accuracy', 'full_params',
'kernel']}
167.         print(f"  参数: {params_to_show}")
168.         print(f"  训练准确率: {best_params_dict['accuracy']:.4f}")
169.
170.         best_svc_params = best_params_dict['full_params']
171.         best_svc = SVC(**best_svc_params)
172.         best_svc.fit(X_train_scaled, y_train) # 在完整训练集上训练
最佳模型
173.         best_results_per_kernel[kernel_name_display] = {
174.             'model': best_svc,
175.             'accuracy': best_params_dict['accuracy'],
176.             'params': best_params_dict
177.         }
178.     else:
179.         print(f"\n 警告: 未找到 {kernel_name_display} 核的有效结
果。")
180.         best_results_per_kernel[kernel_name_display] = None
181.
182. # --- 6. 加载预测数据并进行预测 ---
183. print("\n--- 加载预测数据并进行 NDVI 预测 ---")
184. try:
185.     # 预测数据文件路径（替换为您的实际路径）
186.     predict_file_path = r"C:\Users\31105\Desktop\xlsx\人工干 2.xlsx"
187.     predict_data = pd.read_excel(predict_file_path, sheet_name='Sheet1')
188.     print(f"\n[数据加载] 成功加载预测数据 '{predict_file_path}'")
189.     print(f" 数据维度: {predict_data.shape[0]} 行, {predict_data.shape[1]}
列")
190. except FileNotFoundError:
191.     print(f"错误: '{predict_file_path}' 文件未找到。请确保文件路径正确。
")
192.     exit()
193. except Exception as e:
194.     print(f"读取预测数据 Excel 时发生意外错误: {e}")
195.     exit()
196.
197. # 检查预测数据是否有足够的特征列
198. if predict_data.shape[1] < 5:
199.     print(f"错误: 预测数据 Excel 文件只有 {predict_data.shape[1]} 列,
不足以提取 5 个特征。")
200.     exit()

```

```

201.
202. # 提取预测数据的特征 (第 2-6 列)
203. X_predict = predict_data.iloc[:, 1:6] # 第 2-6 列作为特征
204. predict_feature_names = list(X_predict.columns)
205. print(f" 预测数据特征列: {predict_feature_names}")
206.
207. # 确保预测数据的特征名称与训练数据一致
208. if predict_feature_names != feature_names:
209.     print("错误: 预测数据的特征列名称与训练数据不一致。")
210.     exit()
211.
212. # 标准化预测数据
213. X_predict_scaled = scaler.transform(X_predict) # 使用训练数据的 scaler
转换
214.
215. # 选择最佳模型进行预测 (以准确率最高的核为例)
216. best_kernel = max(best_results_per_kernel.items(), key=lambda x:
x[1]['accuracy'] if x[1] else -1)
217. best_model_name, best_model_info = best_kernel
218. best_model = best_model_info['model']
219. print(f" 使用最佳模型: {best_model_name} 核 (准确率:
{best_model_info['accuracy']:.4f})")
220.
221. # 预测 NDVI 值
222. y_predict = best_model.predict(X_predict_scaled)
223. print(f" 预测完成, 预测的 NDVI 值数量: {len(y_predict)}")
224.
225. # 将预测结果添加到预测数据最后一列
226. predict_data['预测 NDVI'] = y_predict
227.
228. # --- 7. 输出预测结果到新的 Excel 文件 ---
229. output_file_path = r"C:\Users\31105\Desktop\xlsx\人工干预带 NDVI.xlsx"
230. predict_data.to_excel(output_file_path, index=False, sheet_name='Sheet1')
231. print(f"\n[结果保存] 预测结果已保存至 '{output_file_path}'")
232.
233. # 打印部分预测结果以供检查
234. print("\n--- 预测结果预览 (前 5 行) ---")
235. print(predict_data.head(5))
236.
237. print("\n--- 执行完毕 ---")

```